

任务三：综合健康类别预测

设计思路、训练评价与模型调用说明

2026 年第五届“创新杯”大学生大数据挑战赛 A 题

队伍编号：DATA2600655

Python 3.11 | scikit-learn 1.8.0 | 随机种子 2026

摘要

任务三要求依据多维生活方式、心理状态与生理健康信息识别个体综合健康类别。本文首先统一标签口径，将原始数据中的 Poor 并入 Average，形成 Average、Good 与 Excellent 三分类；随后对 10,000 条记录开展缺失机制、标签定义关系和代理变量审计。为区分竞赛性能与可解释泛化能力，设置 FULL、NO_DIRECT 和 NO_COMPOSITE 三种特征口径。模型选择采用固定 20% 锁定留出集与开发集五折折外预测，在同一划分上比较多项逻辑回归、随机森林、直方梯度提升、ExtraTrees 和三层 MLP，并仅依据 OOF 概率搜索融合权重。NO_DIRECT 融合模型的最优权重为 Logistic 0.60、HistGradientBoosting 0.10、ExtraTrees 0.30，开发集 OOF 准确率为 0.9176；一次性锁定留出集 ACC 为 0.9260、Macro-F1 为 0.9266、Macro-AUC 为 0.9887。FULL 竞赛模型 ACC 为 1.0000；NO_COMPOSITE 敏感性口径 ACC 为 0.7950。混淆矩阵表明误差集中于相邻健康等级，置换重要性进一步量化了综合健康老龄化评分、心血管风险、年龄、糖尿病风险与血糖水平的预测贡献。最终模型在全部样本上重训并固化预处理、类别映射及推理接口，可直接生成任务三三分类预测结果。

关键词：综合健康类别；折外预测；概率融合；ExtraTrees；多层感知机；置换重要性；特征口径审计

1 问题定义与标签口径

原始数据包含 64 个字段，其中 Wellness_Category 为任务三目标变量。题面规定输出 Excellent、Good 和 Average 三类，而原始数据还包含 114 条 Poor 记录。为保留全部样本并与评测口径一致，将 Poor 统一映射为 Average，最终三类样本数分别为 2,251、4,429 和 3,320。Person_ID 仅作为样本索引，不进入模型。




图 1 原始四分类标签与官方三分类映射

标签审计显示，Fitness_Level 与原始四分类标签逐行一致，Health_Score 也可由固定阈值完全重构标签。因此 FULL 口径用于表示提交字段完整时的竞赛性能；NO_DIRECT 删除 Fitness_Level 与 Health_Score，用于评价去除直接定义变量后的泛化能力；NO_COMPOSITE 进一步删除 Healthy_Aging_Score 及六项综合风险变量，用于量化基础行为、心理和生理变量的独立信息量。

表 1 任务三特征口径定义

特征口径	删除字段	用途
FULL	无	竞赛模型与性能上限
NO_DIRECT	Fitness_Level、Health_Score	模型选择与解释主线
NO_COMPOSITE	NO_DIRECT 字段及综合风险代理变量	严格敏感性分析

2 数据处理与特征工程

数据处理全部封装在训练折内部。数值变量采用中位数插补；类别变量采用众数插补，其中 Exercise_Type 与 Workout_Intensity 的结构性缺失记为 None，Alcohol_Consumption 同时保留缺失指示变量。逻辑回归与 MLP 使用 One-Hot 编码和标准化；树模型采用 OrdinalEncoder 并设置未知类别编码为-1。

时间变量首先转换为分钟，再采用正余弦周期编码，以保持 23:50 与 00:10 在圆周上的邻近关系。在原始字段基础上构造跨午夜标记、计算睡眠时长、睡眠中断密度、屏幕时间睡眠比、每周运动总分钟、单位久坐时长步数、果蔬摄入总量、含糖饮料—快餐指数、焦虑—抑郁指数、情绪—满意度指数、精力—疲劳差值、脉压、平均动脉压与重算 BMI 等变量。

表 2 预处理与特征工程矩阵

模块	处理方法	实现目的
时间特征	分钟转换、sin/cos 周期编码、跨午夜标记	保留时间周期与邻近关系
缺失处理	折内中位数/众数插补、结构性缺失显式编码	避免验证信息进入训练
行为交互	运动总量、久坐效率、饮食组合、屏幕睡眠比	刻画生活方式联合效应
心理交互	焦虑抑郁、情绪满意度、压力工作交互	刻画心理状态耦合
生理派生	脉压、平均动脉压、重算 BMI	增强生理风险表达

3 训练协议与候选模型

使用随机种子 2026 进行分层划分，80%样本构成开发集，20%样本构成一次性锁定留出集。开发集内部采用五折 StratifiedKFold 生成 OOF 概率。模型、融合权重和评价口径确定后，锁定留出集仅评价一次；最终提交模型再使用全部 10,000 条样本重训。

- 多项逻辑回归：类别权重 balanced，最大迭代 800，用于建立稳定线性概率基线。
- 随机森林：450 棵树，max_features=sqrt，使用 balanced_subsample 类别权重。
- HistGradientBoosting：learning_rate=0.08，max_iter=260，max_leaf_nodes=31。
- ExtraTrees：600 棵极端随机树，max_features=0.8，使用 balanced 类别权重。
- MLP：128-64-32 三隐藏层，ReLU 与 Adam，批量 128，初始学习率 8×10^{-4} 。

表 3 NO_DIRECT 开发集五折 OOF 模型比较

模型	ACC	Macro-F1	Macro-AUC	Log Loss
Logistic	0.9131	0.9141	0.9881	0.1929
RandomForest	0.8665	0.8656	0.9688	0.3954
HistGB	0.9087	0.9097	0.9841	0.2959
ExtraTrees	0.9010	0.9014	0.9836	0.2558
MLP	0.8936	0.8952	0.9810	0.5568
Fusion	0.9176	0.9189	0.9884	0.1997




图 2 NO_DIRECT 五折 OOF 候选模型比较

最佳单模型为多项逻辑回归，OOF ACC 为 0.9131；HistGradientBoosting、ExtraTrees 与 MLP 的 ACC 分别为 0.9088、0.9010 和 0.8936。结果表明，在当前样本量与特征结构下，经过规范预处理的线性模型具有较强竞争力，模型复杂度不能替代独立验证。

4 折外概率融合

在 Logistic、HistGradientBoosting、ExtraTrees 和 MLP 的 OOF 概率上，以 0.05 为步长搜索非负单纯形权重。选择顺序依次为 ACC 最大、Macro-F1 最大和 Log Loss 最小。最优权重为 0.60、0.10、0.30 和 0，融合 OOF ACC 提升至 0.9176，Macro-F1 提升至 0.9189。MLP 完成训练并参与同折比较，其概率未提供稳定增量，故最终融合权重为 0。

表 4 OOF 概率融合权重

一级模型	融合权重	模型作用
Logistic	0.60	稳定线性概率边界
HistGradientBoosting	0.10	补充非线性分段关系
ExtraTrees	0.30	补充高阶交互与局部边界
MLP	0.00	神经表格基线

5 锁定留出集评价

表 5 NO_DIRECT 锁定留出集模型比较

模型	ACC	Macro-F1	Macro-AUC	Log Loss
Logistic	0.9235	0.9241	0.9890	0.1854
RandomForest	0.8645	0.8644	0.9704	0.3843
HistGB	0.9180	0.9194	0.9848	0.2818
ExtraTrees	0.9105	0.9108	0.9834	0.2518
MLP	0.8960	0.8976	0.9825	0.5719
Fusion	0.9260	0.9266	0.9887	0.1944

一次性锁定留出集上，融合模型取得 ACC=0.9260、Macro-F1=0.9266、Macro-AUC=0.9887、Log Loss=0.1944。Average、Good 与 Excellent 召回率分别为 0.9356、0.9131 和 0.9367；错误集中在相邻健康等级，Average 与 Excellent 之间无跨两级误判。




图 3 NO_DIRECT 融合模型五折 OOF 混淆矩阵




图 4 NO_DIRECT 融合模型 One-vs-Rest ROC 与 PR 曲线

三类 ROC-AUC 和平均精确率均保持较高水平，说明模型对不同健康等级具有稳定排序能力。概率列在训练、融合与输出阶段固定按 Average、Good、Excellent 排列，避免类别顺序不一致造成指标偏差。

6 概率可靠性与变量解释




图5 NO_DIRECT 融合模型可靠性曲线

可靠性曲线整体接近理想对角线，模型概率能够支持风险排序与置信度解释。锁定留出集未呈现系统性过度自信，因此最终模型不追加额外温度缩放。




图6 NO_DIRECT ExtraTrees 锁定留出集置换重要性

对 NO_DIRECT ExtraTrees 执行 5 次重复置换，前五位变量依次为 Healthy_Aging_Score、Cardiovascular_Risk、Age、Diabetes_Risk 和 Blood_Sugar_Level。置换重要性表示模型预测对变量的依赖程度，用于解释特征贡献与敏感性，不作因果推断。

7 深度基线与特征口径消融



图7 MLP 训练收敛曲线

MLP 训练损失在约 20 轮后进入稳定区间，表明优化过程正常收敛；其 OOF ACC 为 0.8936。该结果用于验证神经表格分支的实际增益，最终模型依据折外结果准入。

表 6 同一 ExtraTrees 模型的特征口径消融

特征口径	ACC	Macro-F1	Macro-AUC	Log Loss
FULL	1.0000	1.0000	1.0000	0.0001
NO_DIRECT	0.9105	0.9108	0.9834	0.2518
NO_COMPOSITE	0.7950	0.7949	0.9379	0.4877




图 8 官方三分类特征口径消融

固定 ExtraTrees 模型后，FULL、NO_DIRECT 和 NO_COMPOSITE 锁定 ACC 分别为 1.0000、0.9105 和 0.7950。直接定义变量显著提高竞赛准确率；去除直接字段后仍保留较强预测能力；进一步剔除综合风险代理变量后，基础行为、心理和生理字段仍可提供有效分类信息。

8 最终模型与预测结果

完成锁定评价后，使用全部 10,000 条有标签样本重训模型。竞赛模式固化 FULL 三分类 ExtraTrees，解释模式固化 Logistic、HistGradientBoosting 与 ExtraTrees 的 NO_DIRECT 概率融合。所有模型文件均包含预处理器与分类器，预测阶段不再重新拟合编码器、插补器或权重。

表 7 最终推理模式

模式	模型文件/组合	输出
competition	FINAL_ExtraTrees_FULLL_3C_all10000.joblib	三分类标签与概率
explanation	0.60 Logistic + 0.10 HistGB + 0.30 ExtraTrees	三分类标签与概率

在任务三目录安装依赖：

```
python -m pip install -r requirements.txt
```

调用 FULL 竞赛模型生成预测：

```
python code/predict_task3.py \  
--input data/A 题数据集.csv \  
--output results/task3_predictions.csv \  
--mode competition
```

调用 NO_DIRECT 解释模型：

```
python code/predict_task3.py \  
--input data/A 题数据集.csv \  
--output results/task3_explanation_predictions.csv \  
--mode explanation
```

输入 CSV 应保留原始字段名；Wellness_Category 可存在或省略。输出 CSV 包含 Person_ID、Predicted_Wellness_Category 以及 Average、Good 和 Excellent 三列类别概率。

9 运行环境与复现方式

表 8 运行环境

项目	版本/参数
操作系统	Windows 10/11 或 64 位 Linux
Python	3.11
NumPy	2.3.5
pandas	2.2.3
scikit-learn	1.8.0
Matplotlib	3.10.8
seaborn	0.13.2
随机种子	2026
并行设置	树模型 n_jobs=-1

执行 python code/train_task3.py 可复现数据审计、五折 OOF、融合权重搜索、锁定留出评价、置换重要性、MLP 收敛曲线、特征口径消融与全量重训。复现结果统一写入 reproduce_results 目录。

10 结论

任务三完成了官方三分类映射、折内预处理、五类候选模型同折比较、OOF 概率融合、一次性锁定留出评价、概率可靠性分析、置换重要性解释和三口径消融。FULL 竞赛模型 ACC 为 1.0000；NO_DIRECT 融合模型锁定 ACC 为 0.9260、Macro-F1 为 0.9266、Macro-AUC 为 0.9887；NO_COMPOSITE 口径 ACC 为 0.7950。最终模型与推理接口能够直接读取原始字段并生成三分类结果，训练协议、随机种子、类别顺序和模型参数均已固化。

参考文献

- [1] Breiman L. Random Forests[J]. Machine Learning, 2001, 45: 5-32.
- [2] Geurts P, Ernst D, Wehenkel L. Extremely randomized trees[J]. Machine Learning, 2006, 63: 3-42.
- [3] Friedman J H. Greedy function approximation: A gradient boosting machine[J]. Annals of Statistics, 2001, 29(5): 1189-1232.
- [4] Wolpert D H. Stacked generalization[J]. Neural Networks, 1992, 5(2): 241-259.
- [5] Niculescu-Mizil A, Caruana R. Predicting good probabilities with supervised learning[C]. ICML, 2005: 625-632.
- [6] Breiman L. Statistical modeling: The two cultures[J]. Statistical Science, 2001, 16(3): 199-231.