

2026 年第五届“创新杯”大学生大数据挑战赛

基于线性主干与残差集成的 综合健康评分预测

复赛 A 题 · 任务三建模报告

队伍编号：DATA2600655

锁定验证集

 $R^2 = 0.9829$

固定随机种子 2026，80%训练、20%
一次性验证；验证集不参与模型选择
与权重搜索。

摘要

针对复赛 A 题任务三的综合健康评分高精度回归问题，本文基于 10,000 条、64 字段的健康生活方式数据，构建“线性主干—非线性残差校正—折外权重融合”的分层预测框架。首先对人口统计、作息、运动、饮食、心理、生理及疾病风险变量进行类型审查，将时间字段转换为周期编码，对连续变量采用中位数插补和标准化，对类别变量采用众数插补与独热编码。数据审计表明 Wellness_Category 由 Health_Score 直接分档形成，故将其作为目标泄露字段在所有训练与推理路径中强制剔除；Healthy_Aging_Score 虽与目标高度相关，但并非目标的确定性映射，作为独立健康代理指标保留并通过消融实验单独评估。模型以岭回归提取稳定的全局线性结构，再由直方梯度提升、ExtraTrees 和梯度提升回归器学习剩余误差，融合权重仅依据开发集五折 OOF 预测确定。实验结果显示，五折 OOF R^2 为 0.9832，固定 20% 锁定验证集 R^2 为 0.9829，RMSE 为 1.6131，MAE 为 1.2865。置换重要性和消融结果共同表明，健康老龄化评分是最强综合代理变量，而心血管风险、BMI、体能水平、糖尿病风险、睡眠质量和运动频率提供了稳定的增量信息。该框架在严格隔离直接泄露字段的条件下获得高精度与良好稳定性，并已固化为可直接调用的全量训练模型。

关键词：综合健康评分；回归分析；残差学习；集成学习；目标泄露；模型解释

1 任务理解与总体思路

任务三要求使用全部可用的有效特征预测连续变量 Health_Score，并以决定系数 R^2 评价模型。问题的核心并非简单扩大模型复杂度，而是在高维异构字段、结构性缺失和强相关健康代理指标共存的条件 下，建立既能获得高精度、又能经受泄露审计和独立验证的回归流程。

本文将预测问题分解为三层：第一层由线性模型恢复健康评分的主要加权结构；第二层由树模型学 习线性主干未解释的阈值效应与交互；第三层在五折折外预测上确定残差校正权重。最终模型只使用训 练阶段可获得的字段，并将直接由目标分档形成的字段永久隔离。

阶段	处理内容	目的
数据审计	字段类型、缺失、唯一标识、目标分 布、泄露关系	明确可用信息边界
特征构建	周期编码、缺失插补、独热编码、标准 化	统一异构变量表达
模型训练	岭回归主干 + 三类残差回归器	兼顾线性稳定性与非线性拟合
模型选择	开发集五折 OOF 权重搜索	避免在锁定验证集上调参
最终重训	全量 10,000 条记录重新拟合	形成测试集调用模型




图 1 目标分布与 Wellness_Category 直接分档关系

2 数据审查与泄露控制

2.1 数据结构与缺失模式

原始数据包含 10,000 条记录和 64 个字段，Person_ID 在全表唯一。连续数值、时间、无序类别和有序风险等级并存。Alcohol_Consumption 缺失 3,014 条，Exercise_Type 与 Workout_Intensity 各缺失 824 条；其余字段完整。缺失具有明确语义：运动类型和强度的空值主要对应无运动场景，饮酒量空值则采用训练折内众数插补并由类别编码吸收其不确定性。

变量组	代表字段	处理方式
人口统计	Age、Gender、BMI、Occupation	数值标准化；类别独热编码
作息睡眠	Wake Up Time、Sleep Time、Sleep Quality	时间周期编码；其余数值保留
运动饮食	Daily Steps、Exercise、Water、Protein	数值插补；结构性缺失显式处理
心理与效率	Stress、Mood、Anxiety、Productivity	连续变量标准化
生理与风险	Blood Pressure、BMI、五类疾病风险	数值标准化；风险等级独热编码
健康代理	Fitness Level、Healthy Aging Score	保留并做单独消融

2.2 目标泄露审计

Wellness_Category 与 Health_Score 之间存在逐段无交叠的确定性区间关系：Poor、Average、Good、Excellent 分别覆盖 27.3–44.9、45.0–64.9、65.0–79.9 和 80.0–100.0。该字段本质上是目标分箱后的标签，若纳入模型会把答案边界直接暴露给算法。因此，代码在特征工程入口处无条件删除该字段，确保训练、验证和外部推理具有同一信息边界。

Healthy_Aging_Score 与目标的 Pearson 相关系数为 0.9388，但两者并非确定性映射，其值域内存在显著的个体差异。考虑到赛题允许使用全部有效特征，本文将其视为独立综合健康代理指标保留，并通过去除该字段的消融实验量化模型依赖程度；报告同时给出不含该代理指标时的性能，便于复核结论边界。




图 2 目标及高相关连续变量的 Pearson 相关结构

3 特征工程

3.1 时间变量周期化

起床时间和入睡时间具有 24 小时周期性。直接使用小时数会错误放大 23:59 与 00:01 之间的距离，因此先将时间转换为分钟 m ，再构造正弦与余弦分量：

$$x_{\sin} = \sin(2\pi m/1440), \quad x_{\cos} = \cos(2\pi m/1440)$$

3.2 缺失与类别处理

全部预处理参数仅在当前训练折内估计。连续变量以中位数插补并附加缺失指示，再进行标准化；类别变量以训练折众数插补，并使用 `handle_unknown='ignore'` 的独热编码，使测试集中出现新类别时仍可稳定推理。Person_ID 仅用于样本对齐，Health_Score 为目标列，均不进入特征矩阵。

3.3 特征信息边界

字段	是否入模	判定依据
Person_ID	否	唯一标识，不含可泛化健康信息
Health_Score	否	预测目标
Wellness_Category	否	由目标分档形成的直接泄露字段
Healthy_Aging_Score	是	独立代理指标；通过消融披露依赖程度
其余生活方式与健康字段	是	赛题允许的有效预测信息

4 模型设计

4.1 线性主干

Health_Score 呈现明显的加权合成特征。岭回归以较低方差恢复全局线性结构，并通过轻微 L2 正则抑制多重共线性导致的系数不稳定。设预处理后特征为 z ，则线性预测为 $\hat{y}_0 = \beta_0 + z^T \beta$ ，优化目标为平方误差与 $\alpha \|\beta\|^2$ 之和，本文 α 取 0.1。

4.2 残差校正与折外融合

线性主干拟合后，以 $r = y - \hat{y}_0$ 作为新目标，分别训练 HistGradientBoosting、ExtraTrees 与 GradientBoosting 回归器。三者从直方分裂、随机化树集成和逐步提升三个互补角度学习阈值效应与高阶交互。最终预测为：

$$\hat{y} = \text{clip}[0,100](\hat{y}_0 + 0.2422 \cdot \hat{f}\text{Hist} + 0.3721 \cdot \hat{f}\text{Extra} + 0.6192 \cdot \hat{f}\text{GBR})$$

权重并非在锁定验证集上试探，而是通过开发集五折 OOF 预测最小化均方误差获得。残差校正项彼此学习的误差结构不同，权重之和无需等于 1；它们只作用于线性主干的剩余误差。最后将预测值截断至评分合法区间[0,100]。

模型	主要参数	功能定位
Ridge	$\alpha=0.1$	全局线性主干


模型	主要参数	功能定位
HistGradientBoosting	320 轮；learning_rate=0.03；15 叶节点；L2=10	平滑阈值效应
ExtraTrees	360 棵树；max_features=0.80；min_samples_leaf=8	随机化交互建模
GradientBoosting	320 轮；learning_rate=0.03；depth=2；Huber 损失	稳健残差逼近

5 实验设计与评价指标

以随机种子 2026 将全体样本固定划分为 80%开发集和 20%锁定验证集。开发集内部采用五折随机交叉验证产生 OOF 预测，用于模型比较和融合权重估计；全部方案确定后，仅对锁定验证集评价一次。随后在不改变参数的前提下使用全部 10,000 条记录重新拟合最终模型。

主要指标为决定系数 R^2 ，同时报告 RMSE 和 MAE。 R^2 衡量模型相对均值基线解释的方差比例；RMSE 对较大误差更敏感；MAE 提供与 Health_Score 同量纲的平均绝对偏差。

数据层	样本量	用途	是否参与权重搜索
开发集	8,000	五折 OOF、模型选择、权重估计	是（仅使用 OOF 预测）
锁定验证集	2,000	最终独立性能评价	否
全量数据	10,000	重训提交模型	参数完全固定

图 3 五折 OOF 的 R^2 稳定性

6 实验结果

6.1 模型比较

模型	OOF R^2	RMSE	MAE
OOF 加权残差集成	0.9832	1.5890	1.2599
线性+GBR 残差	0.9831	1.5940	1.2644
线性+HistGB 残差	0.9830	1.5969	1.2670
线性+ExtraTrees 残差	0.9828	1.6039	1.2731
Ridge 线性主干	0.9810	1.6886	1.3319

岭回归已取得 0.9810 的 OOF R^2 ，说明目标主要受稳定的线性加权结构支配。三类残差回归器均带来一致增益，其中加权残差集成达到 0.9832，优于任一单一校正分支；折间 R^2 范围为 0.9818–0.9846，未出现由个别划分驱动的异常提升。




图 4 候选模型及残差集成的五折 OOF 性能

6.2 锁定验证集结果

最终独立评价

$R^2 = 0.9829$

RMSE=1.6131; MAE=1.2865;
n=2,000

锁定验证集 R^2 与 OOF 结果相差 0.0003，说明权重选择没有产生明显乐观偏差。真实值—预测值散点总体贴近 45°理想线；在高分上限附近，预测截断有效避免超出评分定义域。平均绝对误差约 1.29 分，满足综合健康评分精细回归的要求。




图 5 锁定验证集真实值与预测值

6.3 残差诊断

残差以 0 为中心近似对称，未呈现明显的扇形扩散或大范围系统偏移。高端端受 100 分上限影响出现轻微压缩，但总体误差仍保持稳定。该现象与目标变量的截断分布一致，并已通过合法区间裁剪进行约束。




图 6 锁定验证集残差结构

7 关键驱动因素与健康解释

为避免树模型内部重要性偏向高基数变量，本文在锁定验证集上按原始字段分组置换，并计算打乱单个字段后 R^2 的平均下降量。该方法直接衡量变量对最终预测能力的边际贡献。

特征	R^2 平均下降	标准差
Healthy_Aging_Score	1.1547	0.0179
Cardiovascular_Risk	0.0430	0.0012
BMI	0.0257	0.0006
Fitness_Level	0.0182	0.0005
Diabetes_Risk	0.0173	0.0006
Sleep_Quality_Score	0.0168	0.0008
Exercise_Frequency_Per_Week	0.0152	0.0003
Stress_Level	0.0103	0.0005
Age	0.0085	0.0003
Fast_Food_Meals_Per_Week	0.0066	0.0004
Daily_Steps	0.0051	0.0004
Smoking_Status	0.0039	0.0003




图 7 锁定验证集分组置换重要性（双尺度展示）

Healthy_Aging_Score 是最强综合代理指标，打乱后 R^2 下降约 1.15，表明模型大量依赖其对长期健康状态的汇总信息。其余变量中，心血管风险、BMI、体能水平、糖尿病风险、睡眠质量和运动频率贡献最稳定。方向性上，高体能、良好睡眠和更高运动频率与较高健康评分一致；较高 BMI 及心血管、糖尿病风险对应健康评分下降。上述结论来自预测贡献，不直接等同于因果效应。

8 消融实验与稳健性

特征口径	R²	RMSE	MAE
全部有效特征（剔除直接泄露）	0.9829	1.6131	1.2865
去除 Healthy Aging Score	0.9553	2.6069	2.0703
去除健康衍生评分	0.9383	3.0617	2.4209




图 8 特征口径消融结果

去除 Healthy_Aging_Score 后 R^2 降至 0.9553，说明该代理指标对高精度预测具有重要作用；进一步去除 Fitness_Level 后 R^2 降至 0.9383。即便不使用两项健康衍生评分，模型仍能解释约 93.8% 的目标方差，证明原始生活方式、生理与心理字段本身具有较强预测力。主结果保留 Healthy_Aging_Score 符合“使用全部有效特征”的题意，同时通过消融完整披露模型对其依赖程度。

9 最终模型与调用方式

9.1 文件与模型用途

文件	用途
models/task3_final_model.joblib	使用全量 10,000 条样本重训；用于组委会测试数据预测
models/task3_holdout_model.joblib	仅使用 80% 开发集训练；复核报告中的锁定验证指标
predict_task3.py	加载模型并输出 Person_ID 与预测 Health_Score
train_task3.py	从原始数据复现划分、OOF、图表、模型与全部结果
predictions/task3_validation_predictions.csv	2,000 条验证样本的 ID、真值、预测值与残差

9.2 运行命令

```
python -m pip install -r requirements.txt
python train_task3.py
```

```
python predict_task3.py --input data/task3_test_input_example.csv --output predictions/task3_test_output_example.csv
```

输入 CSV 必须包含 Person_ID 及训练所需原始特征，可以不含 Health_Score 和 Wellness_Category。

脚本自动执行列名兼容、时间周期化、缺失处理和类别编码；若输入包含真值，输出会同时保留 True_Health_Score 以便复核。

10 结论

本文完成了复赛 A 任务三的全流程建模。在严格剔除目标分档泄露字段 Wellness_Category 后，线性主干与三路残差集成在五折 OOF 上取得 $R^2=0.9832$ ，在独立锁定验证集上取得 $R^2=0.9829$ ，OOF 与留出结果高度一致。模型既利用 Healthy_Aging_Score 等综合代理指标捕捉长期健康状态，又通过心血管风险、BMI、睡眠质量、运动频率等变量补充个体差异。完整代码、训练模型、验证预测和图表均已固化，可在标准 Python 环境中直接复现与调用。

参考文献

- [1] Hoerl A E, Kennard R W. Ridge Regression: Biased Estimation for Nonorthogonal Problems[J]. Technometrics, 1970, 12(1): 55-67.
- [2] Breiman L. Random Forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [3] Geurts P, Ernst D, Wehenkel L. Extremely Randomized Trees[J]. Machine Learning, 2006, 63(1): 3-42.
- [4] Friedman J H. Greedy Function Approximation: A Gradient Boosting Machine[J]. The Annals of Statistics, 2001, 29(5): 1189-1232.
- [5] Fisher A, Rudin C, Dominici F. All Models Are Wrong, but Many Are Useful: Learning a Variable's Importance by Studying an Entire Class of Prediction Models Simultaneously[J]. Journal of Machine Learning Research, 2019, 20(177): 1-81.