

2026 年第五届“创新杯”大学生大数据挑战赛题目

复赛 A：健康生活方式与早起习惯数据分析

一、赛题背景介绍

随着现代生活节奏的加快，睡眠习惯、日常饮食与整体健康之间的关联成为了公共卫生与个人健康管理的核心议题。本次竞赛基于“早期起床者健康数据集”，旨在通过机器学习与数据分析技术，深入探索作息习惯与个体身心健康之间的潜在规律。

本次竞赛聚焦于分类任务，要求参赛者利用包含人口统计学、睡眠质量、身体活动、营养摄入、心理健康及生理指标等多维度的丰富特征，构建精准的机器学习分类器。通过三个任务挑战，参赛者不仅需要解决基础的行为预测问题，还需应对更为复杂的健康状态评估任务，从而全面锻炼特征工程、模型调优及数据洞察能力。

二、特征解释

Column 特征名	Description 描述
Person ID	个人唯一标识符
Age	年龄
Gender	性别
Height cm	身高（厘米）
Weight kg	体重（千克）
BMI	身体质量指数（Body Mass Index）
Country	国家
Occupation	职业
Marital Status	婚姻状况
Wake Up Time	起床时间
Sleep Time	入睡时间

Sleep Duration Hours	睡眠时长（小时）
Sleep Quality Score	睡眠质量评分
Number of Night Awakenings	夜间醒来次数
Weekend Sleep Difference Hours	周末睡眠时长差异（小时，通常指周末与工作日的睡眠差值）
Nap Frequency Per Week	每周午休/小睡频率
Screen Time Before Bed Hours	睡前屏幕使用时间（小时）
Exercise Frequency Per Week	每周锻炼频率
Exercise Duration Minutes	每次锻炼时长（分钟）
Exercise Type	运动类型
Daily Steps	每日步数
Morning Workout	是否晨练
Workout Intensity	锻炼强度
Gym Member	是否为健身房会员
Daily Calorie Intake	每日卡路里摄入量
Water Intake Liters	每日饮水量（升）
Fruit Intake Per Day	每日水果摄入量
Vegetable Intake Per Day	每日蔬菜摄入量
Protein Intake Grams	每日蛋白质摄入量（克）
Sugary Drinks Per Week	每周含糖饮料摄入量
Fast Food Meals Per Week	每周快餐食用次数
Breakfast Regularity Score	吃早餐的规律性评分
Smoking Status	吸烟状况
Alcohol Consumption	饮酒量
Stress Level	压力水平
Working Hours Per Day	每日工作时长
Sitting Hours Per Day	每日久坐时长
Outdoor Time Hours	每日户外活动时间（小时）
Social Interaction Score	社交互动评分

Meditation Practice	是否有冥想习惯
Resting Heart Rate	静息心率
Systolic BP	收缩压（高压）
Diastolic BP	舒张压（低压）
Cholesterol Level	胆固醇水平
Blood Sugar Level	血糖水平
Energy Level Score	精力水平评分
Fatigue Level Score	疲劳程度评分
Immune Health Score	免疫力健康评分
Mood Score	情绪评分
Anxiety Score	焦虑评分
Depression Risk Score	抑郁风险评分
Productivity Score	生产力评分
Focus Concentration Score	专注力评分
Life Satisfaction Score	生活满意度评分
Obesity Risk	肥胖风险
Hypertension Risk	高血压风险
Diabetes Risk	糖尿病风险
Cardiovascular Risk	心血管疾病风险
Sleep Disorder Risk	睡眠障碍风险
Health Score	综合健康评分
Fitness Level	体能水平
Healthy Aging Score	健康老龄化评分
Wellness Category	综合健康类别
Early Waker	是否为早起者（核心目标变量）

三、复赛任务

任务一：睡眠质量量化评估（Sleep Quality Assessment）

任务描述：睡眠质量是一个连续的数值变量。请仅使用非睡眠类特征（即不能直

接使用 Sleep Duration 等直接描述睡眠的字段，以模拟通过生活习惯预测睡眠质量场景），构建回归模型预测个体的睡眠质量评分。

预测目标：请预测目标变量 Sleep Quality Score。

要求：提交特征工程分析过程、模型预测结果、模型决定系数 R^2_1 。

任务二：工作效率与活力的驱动因素建模（Work Efficiency Factor Assessment）

任务描述：企业和个人都关注如何通过健康管理提升工作效率。请构建回归模型，预测个体的生产力评分或精力评分。你需要处理特征间的多重共线性问题，并解释哪些因素对提升精力贡献最大。

预测目标：请预测目标变量 Productivity Score。

要求：提交特征工程分析过程、模型预测结果、模型调整决定系数 $\text{adjust} - R^2_2$ 、关键驱动因素的分析说明。

任务三：综合健康评分的终极预测（Comprehensive Health Assessment）

任务描述：Health Score 是一个综合了生理、心理各项指标的最终得分。请利用数据集中所有可用的有效特征，构建一个高精度的回归模型来预测该分数。这是本次比赛的终极挑战，鼓励选手使用深度学习或复杂的堆叠模型（Stacking）。

预测目标：请预测目标变量 Health Score。

要求：提交特征工程分析过程、模型预测结果、模型决定系数 R^2_3 分数。

四、复赛提交说明

（1）每项任务需提交：模型代码、预测结果 CSV 文件（含数据集样本唯一标识 Person ID、真值、预测值）、建模报告（含特征重要性分析、明显指向性、强相关、泄露特征剔除思路、模型选择依据及调参过程）。

（2）组委会将在参赛选手提交的测试集上评估各任务的回归（调整）决定系数，作为最终排名依据。

（3）所有任务需参赛选手自行划分训练集和验证集，禁止使用测试集真值进行任何形式的模型训练或超参数选择。