

2026 年第五届“创新杯”大学生 大数据挑战复赛论文

题 目 基于正则化回归与残差集成的健康生活方式多任务评分预测研究

摘 要

睡眠质量、工作效率与综合健康评分共同反映了个体生活方式、心理状态和生理风险的综合作用。针对 2026 年第五届“创新杯”大学生大数据挑战赛复赛 A 题，本文基于 10,000 条、64 字段的健康生活方式数据，建立以信息边界审计为前提、固定折外验证为主线、融合正则化回归与非线性残差学习的多任务评分预测框架。数据处理中将运动类型和强度的结构性缺失保留为无运动类别，将饮酒量缺失编码为未知类别，对入睡与起床时刻实施周期编码；全体样本固定划分为 8,000 条开发记录和 2,000 条锁定验证记录，所有插补、编码与标准化均在训练折内拟合。

任务一严格仅使用非睡眠类特征，Ridge 回归的开发集 OOF R^2 为 0.6517，锁定验证 R^2 为 0.6345、RMSE 为 0.9450。任务二剔除综合及并发状态代理，采用周期时间编码和 L2 正则化处理多重共线性；Ridge $\alpha=10$ 的 OOF 调整 R^2 为 0.6160，锁定验证调整 R^2 为 0.5942、RMSE 为 0.7186，精力辅助模型 OOF 调整 R^2 为 0.7080。任务三强制剔除由 Health Score 直接分档形成的 Wellness Category，以 Ridge 恢复线性主结构，再由 HistGradientBoosting、ExtraTrees 和 GradientBoosting 学习残差并按 OOF 预测融合，取得 0.9832 的 OOF R^2 和 0.9829 的锁定验证 R^2 ，锁定 RMSE 为 1.6131。

置换重要性、相关矩阵、残差诊断与口径消融表明：运动频率、压力和情绪是睡眠质量模型的主要依赖；睡眠质量、运动频率、早起习惯、压力与晨练共同关联生产力和精力；健康老龄化评分是综合健康预测的首要代理变量，心血管风险、BMI、体能、糖尿病风险、睡眠质量与运动仍提供稳定增量信息。结果说明，严格控制目标派生字段和验证边界后，正则化模型适合前两项可加结构任务，残差集成能够进一步提取综合健康评分中的非线性增益。上述排序反映预测依赖，不直接等同于因果干预效应。

关键词：健康生活方式；睡眠质量；生产力预测；岭回归；残差集成；信息泄露；置换重要性

目 录

1 问题重述与研究思路	1
2 数据理解与质量审计	2
3 基本前提与评价体系	4
4 统一预处理与验证框架	4
5 任务一：非睡眠特征驱动睡眠质量预测	5
6 任务二：工作效率预测与精力驱动分析	10
7 任务三：综合健康评分的残差集成预测	15
8 跨任务结果分析与稳健性讨论	21
9 健康管理建议	22
10 模型优点与局限性	23
11 结论	24
参考文献	24
附录	25

1 问题重述与研究思路

1.1 研究动因

现代健康管理的核心问题已由单一指标监测转向多维信息融合。睡眠质量反映恢复水平，工作效率体现健康状态对行为产出的外在影响，综合健康评分则同时吸收生理、心理和生活方式信息。三项指标彼此关联，却具有不同的输入边界、误差尺度和解释目标。若直接使用全部字段，模型可能依赖目标的派生标签或同批综合评分，得到表面上优异、实际不可推广的结果；若过度删除相关变量，又会损失题目允许使用的有效信息。

因此，本文将复赛三项任务统一为监督回归问题，并把信息边界、验证协议和解释口径置于模型复杂度之前。任务一强调“仅使用非睡眠特征”，任务二强调“多重共线性与调整决定系数”，任务三强调“全部有效特征、高精度与复杂集成”。模型设计采用逐步增强原则：先用正则化线性模型描述稳定主结构，只有在严格折外验证显示存在非线性增益时，方引入树模型或残差融合。

1.2 任务描述

任务	预测目标	主要指标	关键约束
任务一	Sleep Quality Score	R^2	仅使用非睡眠类特征
任务二	Productivity Score	Adjusted R^2	处理共线性并解释精力驱动
任务三	Health Score	R^2	剔除直接泄露，提高精度

表 1 三项任务的目标与核心约束

三个任务均需输出 Person ID、真值与预测值，并说明特征工程、模型选择、调参过程、强相关关系、泄露字段剔除及特征重要性。为保证结果可比较，本文为三项任务使用相同的样本划分逻辑和评价原则，但保留不同任务所需的独立字段口径与模型结构。

1.3 研究思路与主要贡献

1. 建立统一的数据契约与泄露审计流程，区分结构性缺失、普通缺失、标识字段、目标字段、直接派生标签和潜在并发代理。
2. 采用固定 80%开发集、20%锁定验证集与开发集五折 OOF 选模，确保锁定集不参与字段选择、模型比较或超参数确定。
3. 针对任务一、任务二分别以 Ridge 回归稳定处理高维独热编码和共线性，针对任务三以线性主干和残差集成提取非线性增益。
4. 综合置换重要性、相关矩阵、残差分布、折间稳定性及口径消融，形成“性能—稳定性—机理边界”三层证据体系。

三项任务统一建模技术路线




图 1 三项任务统一建模技术路线

2 数据理解与质量审计

2.1 数据基本结构

原始数据包含 10,000 条个体记录和 64 个字段，Person ID 全表唯一且无重复。变量覆盖人口统计、睡眠作息、运动行为、饮食摄入、工作与社会行为、心理状态、生理指标、疾病风险及综合评分等维度。三项回归目标的尺度差异明显：睡眠质量评分范围为 1.0—9.8，生产力评分范围为 2.8—10.0，综合健康评分范围为 27.3—100.0。

变量组	代表字段	建模含义
人口属性	Age、Gender、BMI、Country、Occupation	个体属性与基础体型
睡眠作息	Wake Up Time、Sleep Time、Sleep Duration、Sleep Quality	时间节律与恢复状态
运动行为	Exercise Frequency、Duration、Type、Daily Steps、Morning Workout	活动频率、强度与结构
饮食习惯	Calorie、Water、Fruit、Vegetable、Protein、Fast Food	营养摄入与饮食规律
心理效率	Stress、Mood、Anxiety、Productivity、Focus	心理负担与行为产出
生理风险	Blood Pressure、Blood Sugar、Cholesterol、五类疾病风险	生理状态与慢病风险
综合代理	Health Score、Fitness Level、Healthy Aging、Wellness Category	综合或派生健康表征

表 2 数据变量分组与代表字段

2.2 缺失机制与处理原则

全表共有 4,662 个缺失单元，集中于 Exercise Type、Workout Intensity 和 Alcohol Consumption。前两列各缺失 824 条，并与 Exercise Frequency Per Week 为 0 的样本高度重合，属于“未发生运动”导致的结构性缺失；本文保留为独立 None 类别。Alcohol Consumption 缺失 3,014 条，题包无法区分“不饮酒”与“未记录”，故在训练折内作为显式未知类别处理。其余数值字段当前无缺失，但流水线仍保留中位数插补能力，以适应新的测试输入。

字段	缺失数	缺失率	处理
Exercise Type	824	8.24%	结构性缺失，保留 None
Workout Intensity	824	8.24%	结构性缺失，保留 None
Alcohol Consumption	3,014	30.14%	显式未知类别

表 3 缺失字段审计

2.3 目标分布与尺度差异

目标	最小值	均值	中位数	标准差	最大值
Sleep Quality Score	1.0	6.0202	6.0	1.5857	9.8
Productivity Score	2.8	7.0653	7.0	1.1475	10.0
Health Score	27.3	74.2014	74.6	12.2662	100.0

表 4 三项回归目标的描述性统计

由于三个目标的量纲不同，RMSE 与 MAE 只能在各自评分尺度内解释；跨任务比较主要使用无量纲的 R^2 或 Adjusted R^2 。生产力评分分布相对集中，极端样本较少，正则化模型容易出现向总体均值收缩；健康评分跨度最大，但与多项健康代理具有稳定结构，因此其可解释方差显著高于前两项。

2.4 信息泄露与代理变量审计

泄露审计不以相关系数高低作为唯一识别标准，而是结合字段语义、目标生成关系和推理时可获得性。Wellness Category 由 Health Score 按 27.3—44.9、45.0—64.9、65.0—79.9 和 80.0—100.0 分档形成，属于任务三的直接目标派生标签，必须剔除。任务一则按照题面排除睡眠时刻、睡眠时长、夜间醒来、午睡、睡眠障碍和 Early Waker 等睡眠类字段，同时保守排除可能综合睡眠信息的健康代理。任务二剔除综合健康评分及精力、疲劳、情绪、焦虑、抑郁、专注等并发状态评分，以避免循环解释。

Healthy Aging Score 与 Health Score 的 Pearson 相关系数约为 0.9388，但并非目标的确定性映射。任务三按照“全部有效特征”要求保留该字段，同时单独报告去除该代理后的性能；这种主结果与敏感性结果并列的方式，比简单按高相关阈值删除更能说明模型适用边界。

3 基本前提与评价体系

3.1 基本前提

1. 每条记录代表一个独立个体观测，Person ID 仅用于划分、对齐和输出，不具有可广的预测含义。
2. 开发集与锁定验证集来自同一抽样总体；本文评价属于内部泛化估计，不外推为健康管理效果或时间序列预测。
3. 字段的采集时序未完整给出，因此综合评分与并发状态评分按潜在回流代理进行保守隔离。
4. 类别缺失可能含有行为语义；数值缺失如在测试数据出现，则只使用训练折估计的统计量处理。
5. 相关性、系数和置换重要性只描述模型依赖，不自动证明变量间的因果关系。

3.2 评价指标

设真实评分为 y_i ，预测评分为 $\hat{y}_i$ ，样本数为 n ，设计矩阵有效维数为 p 。本文使用决定系数、调整决定系数、均方根误差和平均绝对误差：

$$R^2 = 1 - \Sigma(y_i - \hat{y}_i)^2 / \Sigma(y_i - \bar{y})^2$$

$$\text{Adjusted } R^2 = 1 - (1 - R^2)(n - 1)/(n - p - 1)$$

$$\text{RMSE} = \sqrt{[\Sigma(y_i - \hat{y}_i)^2/n]}, \quad \text{MAE} = \Sigma|y_i - \hat{y}_i|/n$$

R^2 衡量模型相对均值基线减少平方误差的比例；Adjusted R^2 进一步惩罚特征维度，用作任务二的主指标；RMSE 对较大误差更敏感，MAE 表示评分尺度上的典型绝对偏差。任务二主文按独热编码后的 98 维设计矩阵计算 Adjusted R^2 ，并同时保留按原始变量组数计算的敏感性结果。

3.3 置换重要性与折间稳定性

在每个开发验证折内，将某一原始字段及其全部派生列共同打乱，记录验证 R^2 的下降量。类别字段按原始变量分组置换，避免独热列数量影响排序。重要性在五折上独立计算并汇总均值和标准差；若相关变量共同信息，置换重要性会被分摊，因此本文结合相关矩阵和消融实验解释，而不把重要性数值相加为贡献百分比。

4 统一预处理与验证框架

4.1 时间、数值与类别特征处理

Wake Up Time 和 Sleep Time 位于 24 小时周期，直接用十进制小时会把 23:59 与 00:01 错误地视为相距近 24 小时。本文先把时刻转换为分钟 m ，再构造正弦和余弦分量：

$$\text{time_sin} = \sin(2\pi m/1440), \quad \text{time_cos} = \cos(2\pi m/1440)$$

数值变量在训练折内进行中位数插补和 StandardScaler 标准化；类别变量保留显式缺失水平后独热编码，并对测试集未知类别设置 ignore。全部转换与回归器封装在同一 Pipeline 内，避免在样本划分前利用整体数据估计中位数、类别集合或尺度参数。

4.2 固定划分与折外选模

三项任务均使用随机种子 2026 固定划分：8,000 条样本构成开发集，2,000 条样本构成锁定验证集。开发集内部五折交叉验证，每折 6,400 条训练、1,600 条验证，并保存每条样本仅有一次的 OOF 预测。模型、特征口径和融合权重只依据开发集确定；锁定集在方案冻结后评价一次。完成内部验证后，各任务按既定训练口径固化最终推理模型，论文性能仍统一报告 OOF 和锁定验证结果。

环节	样本/折数	允许操作	禁止操作
开发集	8,000 条	字段审计、候选模型比较	读取锁定集真值调参
五折 OOF	5×1,600 条	选择超参数、搜索融合权重	折外预处理提前拟合
锁定验证	2,000 条	一次性性能与残差评价	反向修改模型或字段
模型固化	既定口径	固化最终推理模型	以训练内结果替代验证

表 5 统一验证协议

4.3 候选模型与选择原则

候选模型覆盖 Ridge 、 ElasticNet 、 Random Forest 、 ExtraTrees 、 HistGradientBoosting 和 GradientBoosting 等线性与树模型。任务一和任务二的目标主要呈可加结构，优先以正则化模型处理独热编码和共线性；任务三先由 Ridge 恢复全局主结构，再由树模型拟合其残差。模型选择关注验证性能、折间波动、字段边界和解释成本，不因候选模型更复杂而自动优先。

5 任务一：非睡眠特征驱动睡眠质量预测

5.1 特征边界与输入契约

任务一要求仅使用非睡眠类特征预测 Sleep Quality Score。本文从 64 列中固定 48 个模型输入字段，其中 34 个数值字段、14 个类别字段；Person ID 和目标列不进入模型。Wake Up Time、Sleep Time、Sleep Duration Hours、Number of Night Awakenings、Weekend Sleep Difference Hours、Nap Frequency Per Week、Sleep Disorder Risk 与 Early Waker 等直接睡眠字段全部排除。Screen Time Before Bed Hours 和 Morning Workout 具有睡前或晨间定义重叠，也按保守口径排除；Health Score、Fitness Level、Healthy Aging Score 与 Wellness Category 作为综合代理同步隔离。

任务一特征边界与固定验证流程




图 2 任务一特征边界与固定验证流程

类别	排除字段	理由
标识/目标	Person ID、Sleep Quality Score	标识不作特征；目标不得进入 X
睡眠类	时刻、时长、夜醒、周末差、午睡、睡眠障碍、Early Waker	题面明确禁止直接睡眠特征
边界类	睡前屏幕时间、晨练	与睡前/晨间时段定义重叠
综合类	Health Score、Fitness Level、Healthy Aging、Wellness Category	防止综合评分回流

表 6 任务一字段排除口径

5.2 模型构建与有限调参

任务一比较 Ridge、Random Forest、ExtraTrees 与 HistGradientBoosting。Ridge 的目标式为平方误差与 L2 惩罚之和，标准化使不同量纲的数值特征在同一正则化尺度上。候选 Ridge α 取 0.01、1 和 1,000，树模型使用固定深度或叶节点上限控制复杂度。预先规定：若原 Ridge $\alpha=1$ 与最佳五折 R^2 均值差不超过 0.002，则保留原基线。

$$\min_{\beta} \|y - X\beta\|_2^2 + \alpha\|\beta\|_2^2$$




图 3 任务一开发集五折模型比较

候选模型	R^2 均值	折间标准差	OOF RMSE
Ridge $\alpha=1$ (入选)	0.651563	0.005342	0.939115
Ridge $\alpha=0.01$	0.651546	0.005339	0.939138
HGB (15 叶)	0.637616	0.005066	0.957666
Ridge $\alpha=1000$	0.624906	0.007042	0.974362
Random Forest	0.581227	0.006547	1.029456
ExtraTrees	0.576213	0.009064	1.035580

表 7 任务一开发集固定五折结果


Ridge $\alpha=1$ 与 $\alpha=0.01$ 的 R^2 均值仅相差 0.000017，未形成实际增益；树模型明显低于，说明经过严格边界控制后，任务一的主要关系更接近稳定可加结构。最终保留 $\alpha=1$ 、solver=svd 的 Ridge 流水线。

5.3 锁定结果与误差诊断

数据口径	样本量	R ²	RMSE	MAE
开发集整体 OOF	8,000	0.651667	0.939115	0.752460
锁定验证集	2,000	0.634460	0.944974	0.748283

表 8 任务一不同评价口径的回归结果

任务一真实值与预测值对照



任务一锁定验证残差诊断




图 4 任务一预测对照与锁定验证残差诊断：（a）预测对照；（b）残差诊断

锁定 R^2 较开发 OOF 下降 0.0172，而 RMSE 基本一致，表明模型未出现明显的验证性能下降。锁定残差均值为 -0.0088，绝对误差中位数为 0.6141 分，90% 分位为 1.5675 分。预测值在评分两端存在向均值收缩，符合正则化线性模型对稀少极端样本的典型表现。

5.4 主要预测依赖与关联结构





图 5 任务一变量结构：（a）置换重要性；（b）主要数值字段相关结构

每周运动频率、压力水平和情绪评分的平均 R^2 下降分别为 0.4926、0.3296 和 0.3156，随后为疲劳水平、焦虑评分和生产率评分。运动频率与目标的单变量 Pearson 相关接近 0，却具有最大的多变量置换重要性，说明其作用依赖于其他变量条件和模型联合结构。精力与疲劳、压力与焦虑、久坐与工作时长等存在高相关，故上述排序只表示固定模型的预测依赖，不解释为增加运动必然提升睡眠质量。

6 任务二：工作效率预测与精力驱动分析

6.1 变量口径与共线性处理

任务二以 Productivity Score 为目标。为降低循环解释风险，主模型剔除 Health Score、Fitness Level、Healthy Aging Score、Wellness Category 四项综合字段，以及 Energy、Fatigue、Immune Health、Mood、Anxiety、Depression Risk、Focus 和 Life Satisfaction 等八项并发状态评分。睡眠时刻经周期编码后保留，Sleep Quality Score、Early Waker 和 Morning Workout 作为题面关注的生活方式因素进入模型。



开发集连续变量中有四组 $|\text{Pearson } r| \geq 0.75$ ：工作时长—久坐时长 0.8734 为、体重—BMI 为 0.8434、运动频率—每日步数为 0.8348、收缩压—舒张压为 0.8320。本文不按单一相关阈值机械删列而是使用标准化与 L2 惩罚收缩共线方向的系数，同时用分组置换重要性评价变量组的整体依赖。





图 6 任务二变量结构：（a）生产力评分分布；（b）主要连续指标相关结构

6.2 候选模型与参数选择

候选集包含 Ridge $\alpha=0.1$ 、1、10、100，ElasticNet、HistGradientBoosting 和 ExtraTrees。所有模型使用相同五折和相同字段范围。预设选择规则为：若 Ridge $\alpha=10$ 的 OOF Adjusted R^2 距最佳模型不超过 0.001，则优先选择 Ridge，以获得更稳定的共线系数和更直接的解释路径。






图 7 任务二模型选择：（a）候选模型比较；（b）特征口径消融

模型	OOF R^2	Adjusted R^2	RMSE	MAE
ElasticNet	0.6211	0.6164	0.7048	0.5612
Ridge $\alpha=10$ （入选）	0.6207	0.6160	0.7052	0.5616
Ridge $\alpha=100$	0.6205	0.6157	0.7054	0.5619
HistGradientBoosting	0.6094	0.6046	0.7156	0.5702
ExtraTrees	0.5949	0.5899	0.7288	0.5805


表 9 任务二候选模型 OOF 比较

ElasticNet 仅领先 Ridge $\alpha=10$ 约 0.00045，触发预设容差规则，故选择 Ridge。口径消融中，剔除综合与并发状态评分的主口径 Adjusted R^2 为 0.6160，略高于仅剔除综合字段的 0.6148 和全字段口径的 0.6142，说明保守字段边界并未以明显性能损失为代价。

6.3 锁定验证与残差分析

数据口径	R^2	Adjusted R^2	RMSE	MAE
开发集 OOF	0.6207	0.6160	0.7052	0.5616
锁定验证集	0.6141	0.5942	0.7186	0.5764
锁定集（按原始变量组调整）	0.6141	0.6042	0.7186	0.5764

表 10 任务二开发 OOF 与锁定验证结果



任务二锁定验证残差诊断




图 8 任务二锁定验证：（a）真实值与预测值；（b）残差诊断

锁定 R^2 比开发 OOF 低 0.0066，RMSE 高 0.0134，整体差异较小。散点沿理想线分布，但低分样本容易被高估、高分样本容易被低估，显示正则化模型对边界样本的收缩。平均绝对误差约 0.58 分，适合群体评分估计和依赖结构分析，不宜作为个体绩效考核的唯一依据。

6.4 生产力与精力驱动因素




图 9 任务二变量重要性：（a）生产力模型；（b）精力辅助模型

排序	生产力模型	R ² 平均下降	精力辅助模型	R ² 平均下降
1	睡眠质量	0.2653	运动频率	0.3945
2	运动频率	0.2464	睡眠质量	0.2547
3	早起习惯	0.2242	压力水平	0.2047
4	压力水平	0.1292	晨练	0.1787
5	晨练	0.0897	入睡时刻	0.0140

表 11 任务二关键生活方式因素

生产力模型中，睡眠质量、运动频率、早起习惯、压力和晨练构成最稳定的预测依赖。精力辅助模型排除生产力及并发心理状态评分后，OOF R²为 0.7116、Adjusted R²为 0.7080，排名前四的运动频率、睡眠质量、压力和晨练与生产力模型高度一致。跨目标一致性增强了结果的稳健性，但横断面数据仍无法确认干预方向。





图 10 任务二入选模型的五折验证稳定性

7 任务三：综合健康评分的残差集成预测

7.1 目标泄露控制与健康代理

任务三使用全部可用有效特征预测 Health Score。Wellness Category 与目标分段边界完全一致，训练和推理入口均强制删除。Person ID 只用于对齐；目标列不进入 X。Healthy Aging Score 虽与目标高度相关，但不是确定性映射，主模型保留，并将“去除 Healthy Aging Score”和“进一步去除健康衍生评分”作为独立消融口径。

任务三目标分布与分档泄露



综合健康评分及高相关连续变量结构




图 11 任务三目标审计：（a）目标分布与分档泄露；（b）高相关连续变量结构

字段	与目标关系	处理	验证方式
Wellness Category	目标确定性分档	强制剔除	检查分段无交叠
Healthy Aging Score	高相关非确定映射	主模型保留	去除该字段消融
Fitness Level	健康综合代理	主模型保留	健康衍生评分联合消融
Person ID	唯一标识	不入模	仅用于划分与输出

表 12 任务三关键字段审计

7.2 线性主干与残差学习

综合健康评分呈现强线性主结构，同时包含风险阈值和多变量交互。本文先以 Ridge 得到主预测 $\hat{y}_{\text{linear}}$ ，再在训练折内计算残差 $e=y-\hat{y}_{\text{linear}}$ ，由 HistGradientBoosting、ExtraTrees 和 GradientBoosting 分别学习残差。最终预测为线性主干与三类残差预测的加权和：

$$\hat{y} = \hat{y}_{\text{linear}} + w_{\text{hist}} \hat{e}_{\text{hist}} + w_{\text{extra}} \hat{e}_{\text{extra}} + w_{\text{gbr}} \hat{e}_{\text{gbr}}$$

融合权重仅使用开发集五折 OOF 预测求解，并允许通过非负加权平衡三个残差学习器。最终权重分别为 0.2422、0.3721 和 0.6192。由于残差学习器预测方向与尺度不同，权重之和不要求等于 1；其目标是最小化 OOF 平方误差。




图 12 任务三候选残差模型与融合性能比较

模型	R^2	RMSE	MAE
OOF 加权残差集成	0.983168	1.588977	1.259917
线性 + GBR 残差	0.983062	1.593958	1.264392

模型	R ²	RMSE	MAE
线性+HistGB 残差	0.982999	1.596912	1.266977
线性+ExtraTrees 残差	0.982850	1.603919	1.273101
Ridge 线性主干	0.980990	1.688646	1.331884


表 13 任务三开发集 OOF 模型比较

残差融合相较 Ridge 主干将 OOF R²提高 0.00218、RMSE 降低 0.0997 分。增益绝对值不大，但在高基线区间仍稳定存在；单一 GBR 残差已接近融合结果，HistGB 与 ExtraTrees 提供互补误差结构，折外加权进一步降低总体误差。

7.3 锁定结果与误差分布

数据口径	样本量	R ²	RMSE	MAE
开发集 OOF	8,000	0.983168	1.588977	1.259917
锁定验证集	2,000	0.982881	1.613125	1.286548

表 14 任务三开发 OOF 与锁定验证结果






图 13 任务三锁定验证：（a）真实值与预测值；（b）残差诊断

锁定 R^2 仅比开发 OOF 低 0.00029，RMSE 增加 0.0241 分，说明融合权重未明显利用开发折偶然性。预测点在 30—100 分范围内紧贴理想线，残差总体围绕 0 分布，均值为 0.0347；但高分区间的残差离散略有扩大，提示综合评分上界附近仍存在边界和异方差效应。

7.4 变量重要性与口径消融




图 14 任务三置换重要性：（a）首要代理指标；（b）其他关键驱动因素

Healthy Aging Score 的 R^2 平均下降约 1.1547，显著高于其他变量，表明模型主要依赖该综合健康代理恢复评分主结构。为避免首位指标压缩其余变量的图中差异，图 14 采用首位指标与其余变量分组展示。除该代理外，心血管风险、BMI、体能水平、糖尿病风险、睡眠质量、运动频率、压力、年龄和快餐频率仍具有稳定增量信息。




图 15 任务三稳健性检验：（a）特征口径消融；（b）五折验证稳定性

特征口径	R^2	RMSE	MAE
全部有效特征（剔除直接泄露）	0.9829	1.6131	1.2865
去除 Healthy Aging Score	0.9553	2.6069	2.0703

特征口径	R ²	RMSE	MAE
去除健康衍生评分	0.9383	3.0617	2.4209

表 15 任务三锁定验证特征口径消融

去除 Healthy Aging Score 后，模型仍取得 0.9553 的 R²；进一步去除健康衍生评分后 R²为 0.9383。这说明主结果确实依赖综合代理，但生活方式、生理风险和心理变量仍包含较强的独立预测信息。五折 R²范围为 0.9818—0.9846，折间波动很小，支持模型结构稳定。

8 跨任务结果分析与稳健性讨论

8.1 三任务性能对比

任务	入选模型	开发 OOF 指标	锁定验证指标	锁定 RMSE/MAE
任务一	Ridge $\alpha=1$	R ² =0.6517	R ² =0.6345	0.9450 / 0.7483
任务二	Ridge $\alpha=10$	Adj.R ² =0.6160	Adj.R ² =0.5942	0.7186 / 0.5764
任务三	线性主干+残差集成	R ² =0.9832	R ² =0.9829	1.6131 / 1.2865

表 16 三项任务最终内部验证性能

任务一和任务二的 R²约为 0.61—0.65，反映在排除直接睡眠字段和同批状态代理后，生活方式与健康变量能够解释目标的主要但非全部差异。任务三显著更高，原因并非仅由模型复杂，而是 Health Score 与 Healthy Aging Score、Fitness Level 及多项疾病风险具有共同的稳定健康结构。三者 RMSE 尺度不同，不能以任务三绝对误差较大据此评价其相对性能较差。

8.2 模型复杂度与实际收益

前两项任务中，树模型没有超过正则化线性模型；任务二 ElasticNet 的微弱领先低于预设容差，选择 Ridge 可降低解释和应用复杂度。任务三中，Ridge 已取得 0.9810 的 OOF R²，残差集成进一步提升到 0.9832。由此可见，模型复杂度应由严格折外增益驱动：当关系近似可加且共线性显著时，正则化模型更稳健；当线性主结构之上仍存在阈值和交互时，残差学习比直接用单一复杂模型更高效。

8.3 泄露审计与敏感性边界

本文的三项主结果均不使用目标列或唯一标识。任务一采用最严格的非睡眠与综合代理隔离；任务二的保守字段口径在 Adjusted R²上不低于全字段对照；任务三删除确定性分档标签，并通过去健康代理消融报告性能下界。需要强调的是，相关或并发评分的生成时序未完全公开，字段剔除只能减少而不能绝对证明不存在语义回流。正式测试时应确保输入字段与训练契约一致。

8.4 误差模式与适用范围

三项模型的锁定残差均以 0 附近为中心，开发与锁定指标接近。任务一、二在评分边界呈均值回归，任务三高分段的残差方差略增。模型适合比赛设定下的同分布评分预测、群体变化分析和风险筛查，不应直接用于健康诊断、劳动绩效考核或个体干预强度决策。若应用于新地区、新职业或不同采集时间，应重新开展外部验证、分布变化监测和校准。

9 健康管理建议

9.1 睡眠—运动—压力的共同作用

任务一中运动频率、压力和情绪处于主要预测依赖；任务二中睡眠质量、运动频率、早起习惯、压力与晨练同时关联生产力，精力辅助模型也复现了运动、睡眠和压力的前三结构。跨目标重复出现的变量比单一模型中的单项高排名更值得关注。这提示健康管理可优先建立睡眠、运动和压力的联合监测指标组，而非分别持续记录单一指标。

9.2 综合健康风险的分层管理

任务三显示心血管风险、BMI、体能水平、糖尿病风险、睡眠质量和运动频率在综合代理之外仍有稳定增量。对于综合健康评分较低人群，可按“基础生理风险—体能与运动—睡眠与压力”三层复核：先识别高血压、糖尿病和心血管风险，再评估体能、BMI 与日常活动，最后结合睡眠质量和心理压力制定生活方式支持方案。

9.3 解释结果的使用边界

模型依赖不能直接转化为“提高某变量即可提升若干分”的干预结论。运动频率与步数、压力与焦虑、BMI 与体重均存在相关，置换重要性可能在变量间重新分配。建议将本研究用于候选因素筛选和个体风险特征描述；干预效果仍需时间序列数据、随机对照或准实验设计验证。

10 模型优点与局限性

10.1 模型优点

1. 字段边界严格：将题面约束、直接派生标签和并发代理分别审计，避免把定义关系误写为算法能力。
2. 验证流程统一：三任务均采用固定开发/锁定划分与五折 OOF，预处理在折内拟合，结果可复核。
3. 模型选择克制：前两项保留性能相当但更稳定的 Ridge，任务三仅在 OOF 证据支持时加入残差集成。

4. 解释证据互补：同时使用相关结构、分组置换、残差诊断、折间稳定和口径消融，降低单一解释方法偏差。
5. 工程流程完整：训练、推理、模型对象、逐样本预测与图源数据均与论文指标一致，可直接复现。

10.2 模型局限

1. 数据为横断面个体记录，缺少时间先后与干预信息，不能建立因果效应。
2. 内部锁定验证来自同一数据源，尚未覆盖跨地区、跨职业或跨时间分布变化。
3. 部分综合评分的生成机制未完全公开，虽然实施了字段隔离与消融，仍可能存在未观测语义重叠。
4. 任务一、二的中等 R^2 表明目标仍受未采集因素和测量随机误差影响，边界样本存在均值回归。
5. 任务三依赖 Healthy Aging Score 等综合代理；去除代理后虽仍保持较高 R^2 ，但精度明显下降。

11 结论

本文围绕复赛 A 题建立了统一而分层的三任务健康评分回归框架。通过结构性缺失识别、时间周期编码、折内预处理、固定 OOF 选模和锁定验证，任务一的非睡眠 Ridge 模型取得 0.6345 的锁定 R^2 ；任务二的共线性 Ridge 模型取得 0.5942 的锁定 Adjusted R^2 ，并识别睡眠质量、运动频率、早起习惯、压力和晨练为生产力与精力的稳定依赖；任务三在剔除 Wellness Category 直接泄露后，以线性主干和残差集成取得 0.9829 的锁定 R^2 。

研究表明，严格的信息边界与验证设计比盲目增加模型复杂度更能提高结论可信度。对于近似可加且高度共线的睡眠质量和生产力任务，Ridge 提供了性能、稳定性与解释性的良好平衡；对于综合健康评分，残差集成能够在强线性主结构上提取细致非线性增益。跨任务反复出现的睡眠、运动与压力因素，为健康管理提供了可复核的分析线索；其干预意义仍需时间序列与实验研究进一步验证。

参考文献

- [1] Hoerl A E, Kennard R W. Ridge Regression: Biased Estimation for Nonorthogonal Problems[J]. Technometrics. 1970.12(1).55-67.
- [2] Zou H, Hastie T. Regularization and Variable Selection via the Elastic Net[J]. Journal of the Royal Statistical Society: Series B. 2005.67(2).301-320.
- [3] Breiman L. Random Forests[J]. Machine Learning. 2001.45(1).5-32.
- [4] Geurts P, Ernst D, Wehenkel L. Extremely Randomized Trees[J]. Machine Learning. 2006.63(1).3-42.
- [5] Friedman J H. Greedy Function Approximation: A Gradient Boosting Machine[J]. The Annals of Statistics. 2001.29(5).1189-1232.

- [6] Fisher A, Rudin C, Dominici F. All Models are Wrong, but Many are Useful: Learning a Variable's Importance by Studying an Entire Class of Prediction Models Simultaneously[J]. Journal of Machine Learning Research. 2019.20(177).1-81.
- [7] Kohavi R. A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection[C]. Proceedings of the 14th International Joint Conference on Artificial Intelligence. Montreal. Morgan Kaufmann. 1995.1137-1143.
- [8] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine Learning in Python[J]. Journal of Machine Learning Research. 2011.12.2825-2830.

附录

附录 A 软件环境与模型参数

任务	Python	scikit-learn	核心模型	随机种子
任务一	3.12.13	1.8.0	Ridge $\alpha=1$, solver=svd	固定哈希划分
任务二	3.13.13	1.8.0	Ridge $\alpha=10$	2026
任务三	3.12.13	1.8.0	Ridge+三类残差回 归器	2026

表 A1 三项任务主要实现环境

三项任务的完整训练模型、源代码、逐样本 OOF 与锁定预测、指标表及图源数据均保存在对应完成包中。任务一调用入口为 `code/predict_task1.py`，任务二和任务三分别为 `predict_task2.py` 与 `predict_task3.py`；推理输入必须包含 Person ID 及训练契约所需原始字段，输出包含编号与预测评分。

附录 B 主要算法流程

步骤	操作	输出
1-2	校验字段与唯一标识；固定开发集与锁定验证集	审计记录与划分清单
3-4	折内拟合预处理；生成 OOF 并按预设规则选模	流水线、模型比较与折外预测
5-6	一次性评价锁定集；固化最终模型并校验无目标推理	真值、预测、残差、指标与模型

表 B1 可复现训练流程

附录 C 提交材料结构与命名

平台最终提交三项文件：参赛论文 `ADATA2600655.pdf`、签字承诺书 `ADATA2600655cns.pdf` 以及支撑材料 `ADATA2600655model.zip`。

`ADATA2600655model.zip` 根目录放置 `README_运行说明.pdf` 和 `DATA2600655 AI 使用说明.pdf`。

任务材料按 `01_task1`、`02_task2` 和 `03_task3` 分类整理；每个任务文件夹包含了 `code`, `models`, `predictions` 和对应的 `task1_model_report.pdf`, `task2_model_report.pdf` 或 `task3_model_report.pdf`。