

2026 年第五届“创新杯”大学生 大数据挑战赛论文

题 目 融合可解释集成学习与深度表格建模的健康生活方式多任务分类研究

摘 要

现代生活中有关睡眠、运动、饮食及心理诸项因素同属一个非线性的健康系统，本文就早起现象、健康分数及总体健康类别的三者关系做分析，提出用标签定义审计的方式结合传统机器学习、集成方法及神经表格所代表的基线来构造处理多任务的健康信息分析体系。

本文首先对包含 10000 条个体记录、64 个字段的数据进行了系统审查。研究者识别出 Exercise Type 与 Workout Intensity 的结构性缺失，将其编码为 None，对 Alcohol Consumption 保留 Unknown 类别与缺失指示，所有插补、编码、标准化、采样和筛选均在训练折内拟合，在此基础上构造了时间周期、睡眠一致性、运动总量、营养暴露、心理风险、血压派生量和疾病风险聚合特征并通过 FULL、NO_DIRECT/NO_TIME 和 NO_COMPOSITE 口径隔离直接定义变量与综合代理变量。

任务一比较逻辑回归、Random Forest 与 XGBoost，在 3 个随机种子 5 折重复分层交叉验证后，FULL 口径 Random Forest 的 ACC1 为 1.0000，去除直接作息及跨任务综合字段后 L2 逻辑回归 ACC 为 0.7685、ROC-AUC 为 0.8355。任务二在训练折内按四分位数构造了四级有序标签，以 Ordinal Logistic 和 LightGBM 生成折外概率并由逻辑回归 Stacking 融合，竞赛口径 ACC2 为 0.8945；严格去代理变量口径 ACC 为 0.7790，二次加权 Kappa 为 0.9119，且无跨两级以上严重误判。任务三将原始 Poor 并入 Average 以符合三分类，在 NO_DIRECT 口径下比较五类模型并进行 OOF 权重搜索，最终 Logistic、HistGradientBoosting 与 ExtraTrees 按 0.60 : 0.10 : 0.30 融合，锁定留出集 ACC 为 0.9260，Macro-F1 为 0.9266，Macro-AUC 为 0.9887。

FULL 口径下三项 ACC 依次为 1.0000，0.8945 和 1.0000，内部加权估算值为 95.78，去除定义/代理变量后的可信解释口径加权估算值为 83.57。定义变量隔离、混淆矩阵、ROC/PR、可靠性曲线、SHAP、模型系数、置换重要性及特征口径消融共同表明：直接定义字段决定了性能上限，而睡眠规律、运动行为、心理压力、健康老龄化、心血管与糖代谢风险仍提供稳定的增量信息。该框架能够兼顾竞赛精度、模型可复现性与健康解释边界，为个体风险筛查和生活方式干预提供量化参考。

关键词：健康生活方式；多任务分类；数据泄漏审计；有序 Stacking；折外融合；模型可解释性

目 录

1 问题重述.....	1
2 数据理解与初步分析.....	2
3 基本假设与符号说明.....	5
4 数据预处理与特征工程.....	5
5 任务一：早起行为预测与定义变量审计.....	9
6 任务二：基于有序学习与 Stacking 的健康等级预测.....	11
7 任务三：健康综合类别预测的严格建模与折外融合.....	15
8 模型评价与结果分析.....	19
9 多维可视化与模型解释.....	22
10 健康管理启示.....	22
11 模型优点与局限性.....	23
12 结论.....	24
参考文献.....	21
附录.....	25

1 问题重述

1.1 研究背景

睡眠规律、体育锻炼、饮食结构、心理压力以及基础生理指标是共同构成个体健康状态的重要影响因素。单一指标通常难以全面反映个体健康水平，而不同因素之间还可能存在的显著的非线性关系和交互效应，例如较长的睡眠时长并不必然对应更好的健康状态，其作用还可能受到睡眠质量、夜间醒来次数、工作时长和心理压力等因素的共同调节。

本题所提供的数据涵盖人口统计学、睡眠行为、运动习惯、营养摄入、心理健康、生理指标及疾病风险等多个维度并要求分别解决早起行为预测、健康评分等级预测和综合健康类别预测三个分类问题。这三个任务复杂程度逐步提升，既涉及缺失值、异常值及类别变量的常规处理；也涉及有序分类、类别不平衡、高维非线性关系和模型解释等重要问题。

1.2 任务描述

任务一：早起行为预测

我们根据个体人口属性、睡眠习惯、生活方式和健康指标建立了二分类模型，预测个体是否属于早起者，即目标变量 Early Waker。

任务一的核心在于：

- 1.处理时间型变量及类别变量；
- 2.识别早起行为的主要影响因素；
- 3.建立具有较高准确率和可解释性的二分类模型。

任务二：健康评分等级预测

Health Score 为连续型综合健康评分，我们首先按照训练集评分分布将其转换为 Poor、Average、Good 和 Excellent 四个具有顺序关系的等级，再根据生理、疾病风险、体能和生活方式变量预测其所属等级。

任务二不仅需要提高分类准确率，还需要保持预测等级与真实等级之间的一致性，避免将相邻等级误差与跨等级严重误差等同处理。

任务三：综合健康类别预测

我们在任务三中通过个体生活方式、心理情绪、行为特征与生理健康信息预测 Wellness Category。该任务的关键难点不仅在于非线性关系与特征交互，还包括题目要求三分类与原始数据四分类之间的口径统一，以及 Health Score、Fitness Level 等直接定义变量造成的性能虚高。

1.3 研究目标

本文的主要目标为：

- 1.建立统一、无信息泄漏的数据预处理流程；
- 2.针对不同任务选择与目标结构相匹配的模型；
- 3.提高少数类别及边界样本的预测能力；
- 4.从全局和个体两个层面解释模型决策；
- 5.分析睡眠、运动、饮食、心理和生理因素对健康状态的综合作用。




图 1 研究总体技术路线图

2 数据理解与初步分析

2.1 数据基本情况

我们对 A 题数据集进行初步读取后，得到 10000 条样本和 64 个字段。Person_ID 在数据中具有唯一性，未发现重复记录。除 Person_ID 外，其余变量可划分为七类。

特征类别	代表变量
人口统计特征	Age、Gender、Country、Occupation、Marital Status
睡眠作息特征	Wake Up Time、Sleep Time、Sleep Duration Hours、Sleep Quality Score
运动行为特征	Exercise Frequency、Daily Steps、Morning Workout、Workout Intensity
营养摄入特征	Daily Calorie Intake、Water Intake、Fruit Intake、Protein Intake
心理与社会特征	Stress Level、Mood Score、Anxiety Score、Social Interaction Score
生理与疾病风险特征	BMI、Blood Pressure、Blood Sugar、Obesity Risk、Diabetes Risk
综合评价及目标变量	Health Score、Healthy Aging Score、Wellness Category、Early Waker

2.2 缺失值分析

原始数据集中共有 4662 个缺失单元，集中在以下三个变量中。

变量	缺失数量	缺失比例	初步判断
Alcohol Consumption	3014	30.14%	可能同时包含未记录和不饮酒两种情况
Exercise Type	824	8.24%	结构性缺失
Workout Intensity	824	8.24%	结构性缺失

我们进一步检查发现 Exercise Type 和 Workout Intensity 的缺失样本均对应 Exercise Frequency Per Week 等于 0。因此得出这两列缺失并非完全随机缺失，只是表示个体没有运动行为。在本文中我们将其编码为独立类别“None”而非使用众数直接填补。

Alcohol Consumption 的缺失机制无法仅由原始数据区分，为了避免无依据插补引入伪信息，本文将缺失值编码为独立类别 Unknown 并增加缺失指示变量，该处理在三个任务的训练折 Pipeline 中保持一致。




图 2 非零缺失率字段




图 3 标准化关键变量箱线图

2.3 目标变量分布

Early Waker 中，非早起者 5842 人，占 58.42%；早起者 4158 人，占 41.58%，整体属于轻度不平衡。

Wellness Category 原始数据中含 Poor 114 例、Average 2137 例、Good 4429 例和 Excellent 3320 例。

类别	样本数	比例
Excellent	3320	33.20%
Good	4429	44.29%
Average	2137	21.37%
Poor	114	1.14%

题目明确规定任务三为 Excellent、Good、Average 三分类。为保留全部 10,000 条样本并严格符合评测口径，本文将 Poor 并入 Average，得到 Average 2251 例、Good 4429 例、Excellent 3320 例；原四分类结果仅作为标签审计，不作为 ACC3 主结果。

Health Score 的取值范围为 27.3-100，均值为 74.20，中位数为 74.60，其全量数据四分位点约为 66.0、74.6 和 82.8。以上分位点仅用于描述数据分布，在正式建模时为了防止验证集信息进入标签构造过程，分箱边界严格仅在训练集或交叉验证训练折中计算。

任务3 标签范围审计




图 4 任务三原始四分类与官方三分类映射审计

2.4 时间变量处理

Wake Up Time 和 Sleep Time 为字符串形式，不能直接输入模型，本文先将其转换为一天中的分钟数：

$$T=60 \times h+m, \quad T \in [0,1440)$$

我们考虑到 23:59 和 00:01 在实际时间上相邻，而直接分钟编码会将二者视为距离很远，因此进一步采用周期编码：

$$T_{\sin} = \sin\left(2\pi \frac{T}{1440}\right)$$

$$T_{\cos} = \cos\left(2\pi \frac{T}{1440}\right)$$

本文同时构造了以下衍生变量：

起床时间分钟数；

入睡时间分钟数；

是否跨午夜入睡；

通过入睡与起床时间计算的理论睡眠时长；

理论睡眠时长与原始 Sleep Duration Hours 的偏差；

工作日与周末睡眠差异；

睡眠规律性综合指标。

2.5 信息泄漏风险分析

我们初步审查发现部分目标变量与原始特征之间存在确定性或近确定性关系。

1. Early Waker 与 Wake Up Time 之间存在明显的定义性对应关系。在当前数据中，以 06:30 为界进行判断，即起床时间早于 06:30 时标记为 Yes，否则为 No。这样可以完全复现 Early Waker 标签。

2. Wellness Category 与 Health Score 之间存在确定性分段关系：

$$\text{Wellness} = \begin{cases} \text{Poor,} & \text{Health Score} < 45 \\ \text{Average,} & 45 \leq \text{Health Score} < 65 \\ \text{Good,} & 65 \leq \text{Health Score} < 80 \\ \text{Excellent,} & \text{Health Score} \geq 80 \end{cases}$$

该规则在当前数据中可以完全复现 Wellness Category。

在数据处理过程中如果直接将 Wake Up Time 输入任务一模型，或将 Health Score 输入任务三模型，模型可能得到接近完美的准确率，但无法体现真实的预测能力与健康管理价值。因此，本文设置两套实验口径。

竞赛性能口径

使用竞赛明确允许的全部特征，评估模型在官方数据结构下的最高分类准确率。

去定义变量口径

在任务一的 NO_TIME_NO_COMPOSITE 口径中剔除 Wake Up Time, Sleep Time, Sleep Duration Hours 及跨任务综合字段；在任务三的 NO_DIRECT 口径中剔除 Health Score 与 Fitness Level, NO_COMPOSITE 口径以进一步剔除综合风险代理变量。

论文主结果同时报告两种口径，以避免将标签定义规则误认为模型学习能力。

3 基本假设与符号说明

3.1 基本假设

1. Person_ID 仅用于标识样本，不具有预测意义。
2. 数据中的各条记录相互独立。
3. 除明确识别出的结构性缺失外，其余缺失可通过观测变量进行合理估计。
4. 训练集与测试集来源于相近的数据分布。
5. 生理指标应满足合理范围，但不随意删除极端值，结合多变量关系判断其真实性。
6. 所有编码、插补、采样和特征筛选过程均仅在训练折中拟合。

3.2 主要符号

符号	含义
X	原始特征矩阵
y_1	Early Waker 标签
y_2	Health Score 等级标签
y_3	Wellness Category 标签

符号	含义
p_{ik}	第 i 个样本属于类别 k 的预测概率
K	分类类别数量
w_m	第 m 个子模型的融合权重

4 数据预处理与特征工程

4.1 数据清洗总体流程

本文建立如下统一处理流程：

原始数据读取 与 字段名称标准化 → 标签定义与泄漏审计 → 分层锁定留出划分 → 训练折内时间解析、缺失处理与类别编码 → 特征构造与筛选 → 采样策略比较 → 候选模型训练 → OOF 模型选择/融合 → 锁定留出评价 → 全量重训与解释输出。

为了防止数据泄漏，所有预处理步骤都封装在 **Pipeline** 或者交叉验证内部，验证集和测试集仅调用训练集拟合得到的参数。

4.2 缺失值处理

原始数据共含 4,662 个缺失单元，Exercise Type 与 Workout Intensity 的 824 条缺失均发生在每周运动频率为 0 的样本中，属于“无运动行为”所致的结构性缺失，统一编码为 None；Alcohol Consumption 的 3,014 条缺失无法区分未记录与不饮酒，因此保留 Unknown 类别并增加缺失指示变量而不进行缺少事实依据的类别猜测。

其余数值变量在训练折内均以中位数填补；类别变量以训练折众数或显式 Unknown 补齐。另外插补器、缺失指示、编码器和标准化器均封装在 **Pipeline** 中，仅由当前训练折拟合后作用于验证折与锁定留出集；三个任务均未使用全量数据统计量完成预处理过程。

4.3 异常值与生理范围修正

我们对连续变量先以四分位距和医学合理范围进行了审计，Age 为 18—80 岁，BMI 为 16.00—44.56，静息心率为 45—100 次/分，收缩压为 94—180 mmHg，舒张压为 55—120 mmHg，未发现明显不可能值，故不按单变量极端性机械删除样本。

由体重和身高复算后的 BMI 平均绝对偏差约 0.009，说明关键生理字段具有良好的内部一致性。对于偏态和极端观测情况，线性模型通过训练折内标准化降低量纲影响，且树模型保持原始排序信息。图 3 展示了离群结构而非作为删样依据。

4.4 类别变量编码

本文中二元类别在语义明确时映射为 0 或 1；逻辑回归、Ordinal Logistic 与 MLP 对无序类别采用 OneHotEncoder，对于 Random Forest、XGBoost、LightGBM、HistGradientBoosting 和 ExtraTrees 采用训练折内 OrdinalEncoder 或模型原生类别处理。

我们在处理数据时所有编码器均设置未知类别容错以保证验证集或测试集中出现新类别时仍可完成推理。本文不使用全量目标编码，在流程上避免了当前样本标签通过类别统计量回流到自身特征这一问题。

4.5 特征构造

特征工程遵循“先恢复可解释的物理含义，再构造有限交互”的原则，所有统计量、插补器和编码器均仅在训练折拟合从而避免验证信息进入特征构造。为保持正文紧凑，核心构造汇总如下：

特征组	代表性构造	主要服务任务	控制原则
时间与睡眠	起床/入睡分钟；sin/cos 周期编码；跨午夜标记；睡眠一致性差值	任务一、三	Wake Up Time 另设去定义变量口径
运动与久坐	每周运动分钟；步数/久坐小时；晨练×规律运动	任务一、三	缺失先补 None 并增加缺失指示
营养与生活方式	果蔬总量；糖饮料+快餐暴露；蛋白质/体重；饮水/体重	任务一、三	分母加极小量并截尾异常比值
心理与社会	焦虑—抑郁指数；情绪—满意度；压力×工作时长；社交×户外	任务二、三	交互项在训练折内标准化
生理与综合风险	脉压；平均动脉压；BMI 复算；疾病风险计数；精力—疲劳	任务二、三	Health Score、Fitness Level 单独隔离审计

其中脉压 $PP=SBP-DBP$ ，平均动脉压 $MAP \approx DBP + (SBP-DBP)/3$ 。比值型特征仅在具有明确健康含义时保留；相关性极高但含义重复的变量在折内筛选阶段择一进入模型。

4.6 特征筛选

我们对不同任务采用了不同的筛选策略：

任务一中使用重复 CV 性能和 SHAP 稳定性筛选早起行为特征。任务二中结合有序系数、LightGBM 增益重要度与互信息网络来审查变量。任务三中以同折模型比较和锁定留出置换重要性评价变量贡献。所有筛选均在训练折内执行并且预测依赖不被解释为因果效应。[3][6][8]

当两个连续变量的 Spearman 相关系数绝对值高于 0.85 时优先保留跨折稳定性更高且健康含义更清晰的变量，同时综合评分及疾病风险变量不直接删除，而是通过 FULL、NO_DIRECT/NO_TIME 与 NO_COMPOSITE 三种口径以量化其敏感性。




图 5 关键健康变量相关性热力图




图 6 MI—Spearman 特征网络（非 MIC）

5 任务一：早起行为预测与定义变量审计

5.1 模型选择依据

任务一比较 L2 逻辑回归、Random Forest 与 XGBoost。[1][2] FULL 口径保留直接作息字段但剔除其他任务的综合标签，用于衡量官方字段条件下的性能上限；NO_TIME_NO_COMPOSITE 口径进一步删除 Wake Up Time、Sleep Time、Sleep Duration Hours、Health Score、Fitness Level、Healthy Aging Score 和 Wellness Category，用于检验非定义性睡眠、运动与生活方式信息。

随机森林分类概率：

$$\hat{p}_k(x) = \frac{1}{B} \sum_{b=1}^B I(h_b(x) = k)$$

最终类别：

$$\hat{y} = \arg \max_k \hat{p}_k(x)$$

其中 B 为树的数量，即第 b 棵树的预测类别。随机森林通过样本重采样与随机特征子集降低单棵树方差，很适合处理该任务中混合类型、非线性且存在交互的特征。

XGBoost 把经验损失与模型复杂度之和定为优化目标：

$$\hat{y}_i^{(t)} = \sum_{m=1}^t f_m(x_i)$$

目标函数：

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t)$$

$$\Omega(f) = \gamma L + \frac{\lambda}{2} \sum_{j=1}^L w_j^2$$

L 为叶节点数， w_j 为叶节点权重。第一项控制拟合误差，第二项限制树结构复杂度。本文使用 XGBoost 检验早起行为中是否存在难以由线性边界表示的阈值与交互关系。

5.2 重复分层交叉验证与参数选择

我们以随机种子 42 划分 20% 的锁定验证集；其余 80% 开发集在 42、2026 和 3407 三个随机种子下分别执行 5 折分层交叉验证。该模型按 15 折平均 ACC 优先选择并依次比较了 F1、ROC-AUC、Log Loss 和跨种子稳定性，同时锁定验证集仅在模型确定后评价一次。

参数	最终值	说明
n_estimators	250	FULL Random Forest
max_features	sqrt	每棵树随机选特征
min_samples_leaf	1	由重复 CV 选择
class_weight	None	未强制重加权

参数	最终值	说明
criterion	gini	节点划分准则
random_state	42	锁定验证划分
严格口径模型	Logistic Regression	C=1, max_iter=3000
重复 CV	3×5 折	seed=42/2026/3407

FULL 口径最终选择 250 棵树的 Random Forest (max_features=sqrt, criterion=gini); XGBoost 以 n_estimators=250, max_depth=4, learning_rate=0.05, subsample=0.9, colsample_bytree=0.9 作为固定候选参与同折比较。

NO_TIME_NO_COMPOSITE 口径最终选择 C=1、max_iter=3000 的 L2 逻辑回归, 模型选择完全由重复 CV 结果决定。

5.3 模型解释

研究过程中采用 SHAP 方法计算每个变量对预测结果的边际贡献:

$$\hat{f}(x) = \phi_0 + \sum_{j=1}^M \phi_j$$

其中 ϕ_0 表示模型在背景数据上的平均输出; ϕ_j 表示第 j 个特征对当前样本预测结果的贡献; $\phi_j > 0$ 推动预测向正类移动; $\phi_j < 0$ 抑制正类预测。

图 7 并列展示 FULL 与 NO_TIME_NO_COMPOSITE 口径的全局 SHAP 重要性, 图 8 给出起床时间和睡眠时长的真实 SHAP 依赖关系, 图 8 中的橙色曲线不是原始变量与标签的简单相关性, 而是控制其余模型输入后, 该变量对模型输出的局部边际贡献变化。两图分别用于区分标签定义规则与非定义性行为因素的边际贡献。[6]




图 7 任务一双口径全局 SHAP 重要性




图 8 任务一关键时间变量 SHAP 依赖关系

FULL 口径中 Wake Up Time 的 SHAP 贡献呈现了接近 06:30 的清晰阈值跃迁，与规则审计一致。我们在删除直接作息字段后，Productivity Score、每周运动频率、Stress Level、Breakfast Regularity Score、Sleep Quality Score 及久坐/工作时长成为主要解释变量，这说明了严格口径仍保留稳定的生活方式信息。

5.4 任务一结果

实验设置	ACC	Precision	Recall	F1	ROC-AUC
FULL Random Forest	1.0000	1.0000	1.0000	1.0000	1.0000
FULL XGBoost (CV)	1.0000	1.0000	1.0000	1.0000	1.0000
NO_TIME Logistic	0.7685	0.7418	0.6803	0.7097	0.8355
NO_TIME XGBoost (CV)	0.7449	0.7199	0.6325	0.6732	0.8090
NO_TIME RF (CV)	0.7242	0.7158	0.5581	0.6271	0.7796

任务一 FULL 锁定验证出 ACC 为 1.0000；去起床时间与综合代理变量后，逻辑回归 ACC 为 0.7685，F1 为 0.7097，ROC-AUC 为 0.8355。前者用于竞赛性能上限，后者用于行为规律解释。

$$ACC_1=1.0000$$

6 任务二：基于有序学习与 Stacking 的健康等级预测

6.1 健康等级构造

Health Score 为连续变量。本文在每个交叉验证训练折内部以 25%、50%和 75%分位点构造 Poor、Average、Good 和 Excellent 四级标签，再将同一训练折得到的边界应用于对应验证折。四个训练折的边界分别约为 65.88—66.00、74.30—74.50 和 82.60—82.80，波动较小且未读取验证折分布。

对第 r 个训练折，计算：

$$q_{r,1}=Q_{0.25}(H_{\text{train}}^{(r)}), \quad q_{r,2}=Q_{0.50}(H_{\text{train}}^{(r)}), \quad q_{r,3}=Q_{0.75}(H_{\text{train}}^{(r)})$$

等级标签为：

$$y_i^{(r)} = \begin{cases} 0, & H_i \leq q_{r,1}, \\ 1, & q_{r,1} < H_i \leq q_{r,2}, \\ 2, & q_{r,2} < H_i \leq q_{r,3}, \\ 3, & H_i > q_{r,3}. \end{cases}$$

这些标签分别对应了 Poor、Average、Good 和 Excellent。

全量数据描述性四分位点约为 66.0、74.6 和 82.8。分位点只由当前训练子折计算再原样应用于对应验证折，这一点与使用全量数据先分箱再交叉验证的不同之处在于后者会把验证集分布提前带入标签构造。

6.2 Ordinal Logistic 回归

普通多分类模型忽略了等级顺序，Ordinal Logistic 通过累计概率建模进入更高健康等级的可能性，其系数可直接解释变量升高对等级迁移方向的影响。[5]

$$\log \frac{P(Y \leq k)}{P(Y > k)} = \theta_k - \beta^T X$$

其中， θ_k 是相邻健康等级间的累计阈值， β 为特征系数，参数在各阈值方程中共享。若某特征对应的 $\beta_j > 0$ ，在其余变量不变时该特征升高会使样本更倾向于进入较高等级，反之则倾向于较低等级。该共享系数结构保留了 Poor-Average-Good-Excellent 的顺序信息。总而言之该模型可用于分析某一变量升高时个体进入更高健康等级的总体趋势。

6.3 LightGBM 模型

LightGBM 用于捕捉非线性关系与高阶交互。[3] 我们通过采用 12 次贝叶斯搜索并以训练折平均 ACC、Macro-F1 与二次加权 Kappa 综合选择最适宜的参数，最优试验使 `n_estimators=540`，`learning_rate=0.0360`，`num_leaves=47`，`max_depth=5` 和 `min_child_samples=91`，最后通过早停得出平均最佳迭代轮数约为 506。

我们通过 LightGBM 模型比较标准多分类交叉熵、类别权重与训练折内 SMOTE 方案发现采样策略的折均 ACC 差异小于 0.002，因此最终选择了以折外性能与严重跨级误差为依据，不将采样视为必然增益。




图 9(a) 任务二超参数搜索轨迹




图 9(b) 任务二采样策略比较

6.4 Stacking 集成

Ordinal Logistic 和 LightGBM 模型分别提供了有序线性关系与非线性交互信息，训练过程中四折 OOF 流程先在每个训练子折拟合预处理器和一级模型，再为未参与拟合的子折生成四级概率。在拼接两组 OOF 概率后由带 L2 正则化的逻辑回归元学习器完成 Stacking。[4]

一级模型的 OOF 概率：

$$z_i = [p_{i,1}^{\text{ord}}, \dots, p_{i,K}^{\text{ord}}, p_{i,1}^{\text{lgb}}, \dots, p_{i,K}^{\text{lgb}}]^T$$

元学习器：

$$P(Y_i=k | z_i) = \frac{\exp(a_k + \gamma_k^T z_i)}{\sum_{c=1}^K \exp(a_c + \gamma_c^T z_i)}$$

最终分类：

$$\hat{y}_i = \arg \max_k P(Y_i=k | z_i)$$

规定一级模型在锁定验证集上的概率由四个折模型平均获得；元学习器只读取开发集 OOF 概率，从而避免使用一级模型对自身训练样本的过拟合输出。最终 Stacking 在严格口径取得 ACC=0.7790、Macro-F1=0.7774、二次加权 Kappa=0.9119。

6.5 类别平衡与等级一致性

已知四分位分箱使各等级总体接近均衡。本文仍在每个训练折内比较原始分布、balanced 类别权重和 One-Hot 后 SMOTE 三种策略，其平均 ACC 分别为 0.7181、0.7186 和 0.7195，差异有限。[7] 我们最终以 OOF Stacking 结果为准，并使用等级 MAE、二次加权 Kappa 和跨两级以上严重误差率共同约束等级一致性。

除准确率外，采用加权 Kappa 衡量预测等级与真实等级的一致性：

完整形式：

$$\kappa_w = 1 - \frac{\sum_{i=1}^K \sum_{j=1}^K w_{ij} O_{ij}}{\sum_{i=1}^K \sum_{j=1}^K w_{ij} E_{ij}}$$

二次权重：

$$w_{ij} = \frac{(i-j)^2}{(K-1)^2}$$

其中 O_{ij} 是真实等级 i 被预测为等级 j 的观察频数， E_{ij} 为独立假设下的期望频数。

相邻一级误判的权重较小，跨越两个或三个等级的误判会受到更大惩罚，因此加权 Kappa 能够对跨越多个等级的错误施加更大惩罚，因此该指标比普通准确率更符合健康等级预测的有序属性。




图 10(a) 任务二 Stacking 预测概率流




图 10(b) Ordinal Logistic 标准化系数

6.6 任务二结果

模型（严格口径）	ACC	Macro-F1	加权 Kappa	严重跨级误差率
Stacking	0.7790	0.7774	0.9119	0.0000
Multinomial Logistic	0.7675	0.7677	0.9059	0.0005
Ordinal Cumulative	0.7390	0.7246	0.9001	0.0035
LightGBM Tuned	0.7315	0.7312	0.8855	0.0055

任务二严格去代理变量口径下，Stacking 锁定验证 ACC 为 0.7790、Macro-F1 为 0.7774、二次加权 Kappa 为 0.9119；竞赛全特征对照口径 ACC 为 0.8945。正文以严格口径为主，竞赛口径作为性能对照。

$$ACC_2=0.8945$$

7 任务三：健康综合类别预测的严格建模与折外融合

7.1 标签口径、直接定义变量与实验边界

原始 Wellness Category 含 Poor、Average、Good、Excellent 四类，但任务目标明确写为 Excellent、Good、Average 三类。为与三分类目标保持一致并保留全部样本，本文采用 Poor 并入相邻 Average 类别的保序映射方案，使三类样本量分别为 2251、4429 和 3320。该处理既保留全部数据又与 ACC3 官方口径一致。图 4 给出了映射前后的真实分布。

原始标签	样本数	官方三分类标签	处理原则
Poor	114	Average	保留样本并并入相邻低健康等级
Average	2137	Average	保持不变
Good	4429	Good	保持不变
Excellent	3320	Excellent	保持不变

研究人员通过数据审计进一步发现 Fitness Level 与原四类标签逐行完全一致，Health Score 按 [45,65,80] 阈值也能 100% 重构标签。因此我们设置了 FULL、NO_DIRECT 和 NO_COMPOSITE 三种口径：FULL 只表示测试字段完整时的竞赛性能上限；NO_DIRECT 在删除 Health Score 与 Fitness Level 后作为模型选择和健康解释主线；同时 NO_COMPOSITE 删除 Healthy Aging Score 及六项综合风险变量用于检验基础生活方式、心理和生理变量的独立信息量。

7.2 数据划分、折内预处理与特征工程

我们在数据划分时将 Person ID 作为唯一索引并按随机种子 2026 进行分层划分：其中 80% 作为开发集，20% 作为一次性锁定留出集。开发集内部使用 StratifiedKFold 生成折外概率，模型选择、融合权重和超参数判断均只读取 OOF 结果，锁定留出集不参与任何选择。所有缺失填补、类别编码与标准化流程均在训练折内拟合。

特征工程在第 4.5 节统一框架上实现：时间变量转换为分钟并采用正余弦周期编码；构造周运动总分钟、单位久坐时长步数、果蔬摄入总量、含糖饮料—快餐指数、焦虑—抑郁指数、情绪—满意度指数、精力—疲劳差值、脉压、平均动脉压及重算 BMI 等交互变量。树模型使用训练折中位数/众数插补与 OrdinalEncoder；逻辑回归和 MLP 使用标准化数值特征与 OneHotEncoder。

7.3 候选模型、真实训练与 OOF 比较

我们在完全相同的 NO_DIRECT 开发集折中划分训练五类候选模型：带类别权重的多项逻辑回归，随机森林，HistGradientBoosting，ExtraTrees[8] 以及三隐藏层结构为 128-64-32 的 MLP。MLP 使用了 ReLU、Adam、初始学习率 8×10^{-4} 、L2 系数 3×10^{-4} 和批量 128，实际收敛过程见图 15(b)。

模型	OOF ACC	Macro-F1	Macro-AUC	Log Loss
Logistic	0.9131	0.9141	0.9881	0.1929
RandomForest	0.8665	0.8656	0.9688	0.3954
HistGB	0.9087	0.9097	0.9841	0.2959
ExtraTrees	0.9010	0.9014	0.9836	0.2558
MLP	0.8936	0.8952	0.9810	0.5568
Fusion	0.9176	0.9189	0.9884	0.1997




图 11 任务三 NO_DIRECT 五折 OOF 模型比较

经过计算发现单模型中逻辑回归 OOF ACC 最高，为 0.9131；HistGradientBoosting 为 0.9087，ExtraTrees 为 0.9010，MLP 为 0.8936。这表明复杂模型并不一定优于经过严格标准化的线性决策边界，模型准入必须依据真实 OOF 结果而不是预设算法等级。

7.4 折外概率加权融合与模型准入

我们对逻辑回归、HistGradientBoosting、ExtraTrees 和 MLP 的 OOF 概率在 0.05 步长单纯形网格上搜索非负权重，以 ACC 优先、Macro-F1 次优、Log Loss 再次优为排序规则。最优组合为 $0.60 \times \text{Logistic} + 0.10 \times \text{HistGB} + 0.30 \times \text{ExtraTrees} + 0.00 \times \text{MLP}$ ，OOF ACC 由最佳单模型的 0.9131 提升至 0.9176，Macro-F1 由 0.9141 提升至 0.9189。

MLP 完成训练与收敛记录后最优权重为 0，说明其概率并未提供稳定增量信息，因此最终融合时不强行纳入深度模型。MLP 保留为已完成的神经表格基线用于验证宏观架构中的“深度模型只有在真实增益成立时才进入融合”这一准入规则。

7.5 锁定留出集结果与误差结构

模型	锁定 ACC	Macro-F1	Macro-AUC	Log Loss
Logistic	0.9235	0.9241	0.9890	0.1854
HistGB	0.9180	0.9194	0.9848	0.2818
ExtraTrees	0.9105	0.9108	0.9834	0.2518
MLP	0.8960	0.8976	0.9825	0.5719
Fusion	0.9260	0.9266	0.9887	0.1944

融合模型在一次性锁定留出集上取得：ACC3=0.9260，Macro-F1=0.9266，Macro-AUC=0.9887。Average、Good 和 Excellent 的召回率分别为 0.9356、0.9131 和 0.9367。混淆矩阵显示没有 Average 与 Excellent 之间的跨两级误判且错误集中在相邻等级边界，符合健康状态连续变化的实际结构。




图 12 任务三 NO_DIRECT 融合模型五折 OOF 混淆矩阵




图 13 任务三 NO_DIRECT 融合模型 ROC 与 PR 曲线




图 14 任务三 NO_DIRECT 融合模型可靠性曲线

我们通过研究发现三类 ROC-AUC 均处于较高水平，PR 曲线在类别比例不同的条件下仍保持稳定同时可靠性曲线整体接近对角线，这一现象说明输出概率具有较好的风险排序与置信度解释能力。融合模型锁定集 Log Loss 为 0.1944，并且未观察到系统性过度自信，故在后续处理中不额外实施温度缩放。

7.6 变量解释、深度基线收敛与因果边界

$$PI_j = \frac{1}{R} \sum_{r=1}^R (S_{\text{base}} - S_{j,r}^{\text{perm}})$$

我们在 NO_DIRECT ExtraTrees 锁定留出集上进行了 5 次重复置换重要性评估，发现前五位分别为 Healthy_Aging_Score、Cardiovascular_Risk、Age、Diabetes_Risk 和 Blood_Sugar_Level。其中 Healthy Aging Score 的置换贡献显著高于其他变量说明它仍是强综合代理变量，所以 NO_COMPOSITE 口径必须作为敏感性分析。置换重要性衡量预测依赖而不代表因果效应，即健康建议仍需结合医学证据与纵向研究。




图 15(a) NO_DIRECT 置换重要性




图 15(b) MLP 真实训练收敛曲线

7.7 特征口径消融、最终重训与提交策略

口径（同一 ExtraTrees）	锁定 ACC	Macro-F1	Macro-AUC	Log Loss
FULL	1.0000	1.0000	1.0000	0.0001
NO_DIRECT	0.9105	0.9108	0.9834	0.2518
NO_COMPOSITE	0.7950	0.7949	0.9379	0.4877




图 16 任务三官方三分类特征口径消融

当控制模型不变时 FULL、NO_DIRECT 和 NO_COMPOSITE 的锁定 ACC 依次为 1.0000，0.9105，0.7950。FULL 的完美结果由 Fitness Level 和 Health Score 的定义关系造成并且删除两者后仍有较强预测力。继续删除综合风险与健康老龄化评分后，性能明显下降，这说明这些代理变量承载大量标签信息，图 16 直观展示这一敏感性。

完成锁定评价后，最终参考模型在全部 10,000 条有标签样本上重新拟合，并保存逻辑回归、HistGradientBoosting、ExtraTrees 及融合权重。测试集中保留 Health Score 与 Fitness Level 分类，本文最后优先使用 FULL 模型以最大化 ACC3，论文机理分析固定采用 NO_DIRECT 融合结果，并且在正式预测 CSV 中包含了 Person ID、真实标签和预测标签。

ACC3 = 1.0000（FULL 口径）；可信解释口径 ACC3 = 0.9260

8 模型评价与结果分析

8.1 评价指标

竞赛主要评价指标为准确率：

$$ACC = \frac{\sum_{i=1}^n I(y_i = \hat{y}_i)}{n}$$

Macro-F1:

$$F1_k = \frac{2P_k R_k}{P_k + R_k}, \text{Macro-F1} = \frac{1}{K} \sum_{k=1}^K F1_k$$

多分类 Log Loss:

$$\log Loss = -\frac{1}{n} \sum_{i=1}^n \sum_{k=1}^K y_{ik} \log p_{ik}$$

内部验证加权估算值为:

$$Score = ACC_1 \times 100 \times 20\% + ACC_2 \times 100 \times 40\% + ACC_3 \times 100 \times 40\%$$

考虑到类别不平衡及等级顺序，本文同时报告：

Precision; Recall; Macro-F1; ROC-AUC;

加权 Kappa; Log Loss; 期望校准误差 ECE; 少数类别召回率。

8.2 总体结果

任务	竞赛口径 ACC	解释口径 ACC	主要模型	权重	口径说明
任务一	1.0000	0.7685	RF / Logistic	20%	Wake Up Time 定义审计
任务二	0.8945	0.7790	Stacking	40%	严格去代理变量为正文主线
任务三	1.0000	0.9260	OOF 加权融合	40%	FULL 竞赛上限; NO_DIRECT 解释
加权合计	0.9578	0.8357	—	100%	两种口径不可混作同一结论

8.3 混淆矩阵分析

任务一中 FULL 混淆矩阵无误判，但在去掉定义变量后仍存在明显边界样本；任务二严格口径的严重跨级误差率为 0，错误主要集中在相邻等级；任务三 NO_DIRECT 融合模型同样没有 Average 与 Excellent 之间的跨两级误判，Average、Good 和 Excellent 召回率分别为 0.9356、0.9131 和 0.9367。

三项任务的混淆矩阵均同时报告样本数与行归一化比例，任务三已按官方三分类口径评价，不再把原始 Poor 类作为独立评测类别；原四分类分布仅用于说明映射过程。

任务二严格口径的跨两级以上严重误判率为 0，说明 Stacking 较好保持了等级顺序；其等级 MAE 为 0.2210，二次加权 Kappa 为 0.9119。

任务三开发集五折 OOF 比较中，融合模型 ACC 为 0.9176，优于最佳单模型逻辑回归的 0.9131。最终权重为 Logistic 0.60、HistGB 0.10、ExtraTrees 0.30、MLP 0；权重完全由 OOF 结果决定。

8.4 ROC 与可靠性分析

任务一绘制二分类 ROC 曲线；任务二和任务三采用 One-vs-Rest 方式绘制各类别 ROC 与 PR 曲线。任务三图 13—14 均由 NO_DIRECT 融合模型真实 OOF 概率生成，不再使用含直接定义变量的 FULL 曲线。

可靠性曲线用于比较模型置信度与真实发生频率。任务二 Stacking 的多分类 ECE 为 0.0206，任务三融合模型可靠性曲线总体贴近理想对角线，两者均未显示需要额外校准的系统性过度自信。

任务三 NO_DIRECT 融合模型的锁定留出集 Macro-AUC 为 0.9887，Log Loss 为 0.1944。可靠性曲线总体贴近理想对角线，现有证据不足以证明温度缩放能够稳定改进，因此不追加没必要的校准步骤。

ROC、PR、可靠性、混淆矩阵及全部数值表均来自于同一固定划分，在当前任务下概率列统一按 Average、Good、Excellent 排序。

8.5 深度表格基线的收敛与准入

任务三中深度基线使用了三隐藏层 MLP，在约 20 轮后真实损失曲线接近收敛，但 OOF ACC 为 0.8936，没有超过线性与树模型，说明低训练损失不能替代独立验证。

基于以上分析我们用真实训练收敛曲线和 OOF 准入结果评价神经表格基线，不以训练损失或二维投影的视觉分离度替代独立验证。

8.6 消融实验

任务	特征口径	ACC	Macro-F1	解释
任务一	FULL	1.0000	1.0000	竞赛上限；含起床时间
任务一	NO_TIME_NO_COMPOSITE	0.7685	0.7586	行为泛化口径
任务二	competition_full	0.8945	0.8949	竞赛对照
任务二	strict_no_proxy	0.7790	0.7774	正文主口径
任务三	FULL	1.0000	1.0000	竞赛上限；含直接定义变量
任务三	NO_DIRECT 融合	0.9260	0.9266	正文可信解释主口径
任务三	NO_COMPOSITE	0.7950	0.7949	严格敏感性分析




图 17(a) 任务一特征口径消融




图 17(b) 任务二特征口径消融

图 16 固定 ExtraTrees 比较任务三三种特征口径；图 17 分别比较任务一与任务二的 FULL/严格口径。

三项结果共同证明直接定义字段和综合代理字段显著抬高竞赛准确率，而去除这些字段后仍保留可解释的行为与健康信号。

9 多维可视化与模型解释

9.1 数据结构层

数据结构层围绕“标签定义—缺失机制—代理变量”组织证据。图 4 明确任务三从原四类到官方三类的映射，缺失率与箱线图支撑折内预处理，FULL、NO_DIRECT、NO_COMPOSITE 消融用于审计直接定义变量和综合代理变量。

数据质量：缺失率图与标准化箱线图用于定位结构性缺失、离群点和量纲差异，用来支撑第 4 章的预处理选择。

我们对关联结构以相关性、互信息和锁定留出集置换重要性互证。任务三不再把普通互信息误称为 MIC；核心解释采用可复现的置换后 ACC 下降量并表明其不具备因果含义。

口径审计：三项任务均并列报告了竞赛口径与去定义或去代理变量口径，避免把标签重构能力误解为健康规律学习。

9.2 模型机理层

模型机理层只用于呈现真实产物。任务一使用 SHAP，任务二结合有序系数与 Stacking 概率流，任务三使用逻辑回归、梯度提升、ExtraTrees 与 MLP 同折对照并以置换重要性解释 NO_DIRECT 树模型。

深度表格分支采用真实可复现的 MLP 基线并与线性、梯度提升和极端随机树执行同折比较。由于 MLP 未提供稳定 OOF 增益，最终融合权重值为 0，即模型复杂度只有在独立验证收益成立时才被接受。

9.3 性能验证层

性能验证层按“模型比较—错误位置—排序能力—概率可信度—特征敏感性”排列。任务三图 11—15 和图 17 均来自本轮真实训练，分别回答模型选择、相邻等级误判、ROC/PR、校准、解释和特征口径影响。

所有任务三性能图均使用 NO_DIRECT 真实 OOF 或锁定留出结果；FULL 仅在消融图中作为竞赛上限出现。

10 健康管理启示

模型解释结果从睡眠、运动、营养、心理及生理风险这五个方面形成健康管理建议。

1.任务一严格口径表明睡眠质量、早餐规律、运动频率、工作时长和压力水平仍具有稳定贡献，因此早起管理应从规律入睡、减少夜间觉醒和晨间行为组合入手而不能把单一 06:30 阈值等同于健康改善。

2.运动频率、每日步数、久坐时间和心血管风险在任务一至三的解释结果中反复出现，因此干预策略应当同时关注每周活动总量与久坐中断情况并结合年龄、血压和血糖风险确定强度。

3.任务二的有序系数与树模型解释共同显示出睡眠质量、每日步数、BMI、血糖及疾病风险会推动健康等级迁移。所以健康评分应作为多维筛查结果使用而不能由单项生活方式指标替代。

4.任务三置换重要性将 Healthy Aging Score、Cardiovascular Risk、Age、Diabetes Risk 和 Blood Sugar Level 列为前五变量，这提示我们综合健康评估应优先识别心血管与糖代谢风险，与此同时结合情绪、压力和生活满意度完善行为干预。

5.模型输出只能作为健康风险筛查和生活方式管理的辅助工具，不能替代专业医学诊断。对于被模型识别为高风险的个体应进一步结合临床检查和专业人员判断。

健康解释以实际 SHAP、系数、置换重要性和消融结果为依据，本文结论属于统计关联，仅可用于健康风险筛查和生活方式管理参考但不能替代临床诊断或因果推断。

11 模型优点与局限性

11.1 模型优点

1.研究者针对三个任务分别采用二分类、有序分类和官方三分类模型；任务三以同划分 OOF 协议比较线性、树集成、梯度提升和 MLP，并以严格准入规则确定了最终概率融合。

2.通过竞赛口径与解释口径并列报告区分标签重构能力与去定义变量后的真实泛化能力。

3.对随机缺失和结构性缺失进行区分，避免不合理填补。

4.模型解释由 SHAP、模型系数、混淆矩阵、ROC/PR、可靠性曲线、置换重要性、训练收敛曲线与特征口径消融共同构成；任务一至三的图片均由固化数据与脚本生成，可与指标表逐项核对。

5.设置直接定义变量隔离实验，降低目标泄漏造成的虚高结果。

6.采用 Pipeline、折外编码和折内采样控制验证过程中的信息泄漏。

11.2 模型局限性

1.数据为横截面数据，只能揭示统计关联，不能证明因果关系。

2.Early Waker 和 Wellness Category 与部分字段存在定义性关系，可能造成竞赛精度与实际预测价值不一致。

3.题面与原始数据存在三分类/四分类差异，本文采用 Poor→Average 保留全部样本。

4.MLP 已完成真实训练但未通过融合准入，这一现象说明了深度表格模型在该数据规模与特征结构下并非必然优于线性和树集成，所以本文以验证收益为模型准入依据，不因算法复杂度而预设优势。

5.Country 和 Occupation 等变量可能会引入群体差异，即模型在新地区或新人群上的泛化能力需要通过进一步检验来评估。

在总的研究过程中部分综合评分由基础特征聚合生成，可能会削弱结论的可迁移性。本文已通过三种特征口径量化其影响，因此在将模型迁移到外部人群时需要重新审查字段生成规则并优先报告去代理变量结果。

12 结论

本次实验完成了从数据审计、训练折内预处理、特征工程、模型比较到可解释评估的三任务统一框架。在任务一中通过定义关系审计和双口径实验区分性能上限与生活方式解释；在任务二中利用有序模型、LightGBM 与折外 Stacking 兼顾分类准确率和等级一致性；在任务三中严格执行原始数据三分类映射，完成五类候选模型五折 OOF、概率融合、锁定留出评价、置换重要性、训练收敛和三口径消融。

三项竞赛口径 ACC 分别为 1.0000, 0.8945, 1.0000。对应加权估算值为 95.78；可信解释口径 ACC 分别为 0.7685、0.7790 和 0.9260，对应内部加权估算值为 83.57。两套结果的差异证明了直接定义字段和综合代理字段对成绩具有显著影响。

三个任务均完成了锁定评价与全量重训。预测阶段中仅调用已固化的预处理器、模型与类别映射生成结果，不再依据测试集标签调整特征、阈值、权重或超参数。

参考文献

- [1] Breiman L. Random Forests[J]. Machine Learning. 2001, 45: 5-32.
- [2] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System[C]. Proceedings of the 22nd ACM SIGKDD. 2016: 785-794.
- [3] Ke G, Meng Q, Finley T, et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree[C]. Advances in Neural Information Processing Systems. 2017, 30: 3146-3154.
- [4] Wolpert D H. Stacked Generalization[J]. Neural Networks. 1992, 5(2): 241-259.
- [5] McCullagh P. Regression Models for Ordinal Data[J]. Journal of the Royal Statistical Society: Series B. 1980, 42(2): 109-142.
- [6] Lundberg S M, Lee S I. A Unified Approach to Interpreting Model Predictions[C]. Advances in Neural Information Processing Systems. 2017, 30: 4765-4774.
- [7] Chawla N V, Bowyer K W, Hall L O, Kegelmeyer W P. SMOTE: Synthetic Minority Over-sampling Technique[J]. Journal of Artificial Intelligence Research. 2002, 16: 321-357.
- [8] Geurts P, Ernst D, Wehenkel L. Extremely Randomized Trees[J]. Machine Learning. 2006, 63: 3-42.
- [9] OpenAI. ChatGPT, GPT-5.6 Sol, OpenAI, 2026-07-27.
- [10] OpenAI. Codex, GPT-5.6 Sol, OpenAI, 2026-07-27.

附录

附录 A 软件环境

模块	核心环境与依赖	验证协议
任务一	Python 3.13.5; pandas 2.2.3; NumPy 2.3.5; scikit-learn 1.8.0; XGBoost 3.1.3; SHAP 0.50.0	seed=42; 3 个随机种子×5 折重复 CV
任务二	Python; scikit-learn; LightGBM; Optuna; imbalanced-learn; SHAP	80/20 外层划分; 开发集 4 折 OOF
任务三	Python 3.12.13; pandas 2.2.3; NumPy 2.3.5; scikit-learn 1.8.0	seed=2026; 80/20; 开发集 5 折 OOF
绘图	Matplotlib 3.10.8; Seaborn 0.13.2; NetworkX; Plotly	PNG 420—600 dpi; 同时保留 PDF

附录 B 训练参数

表中仅列出进入最终比较或融合的关键参数; 完整预处理器、类别映射和全量重训模型均与代码一同固化。

任务/口径	模型	关键参数
任务一 FULL	Random Forest	n_estimators=250; max_features=sqrt; criterion=gini; seed=42
任务一严格口径	L2 Logistic	C=1; solver=lbfgs; max_iter=3000; seed=42
任务二一级模型	Ordinal / LightGBM	Ordinal C=1; LightGBM 540 树、lr=0.0360、leaves=47、depth=5
任务二融合	OOF Stacking	4 折 OOF 概率; L2 逻辑回归元学习器
任务三融合	Logistic / HistGB / ExtraTrees	权重 0.60 / 0.10 / 0.30; MLP 权重 0; seed=2026

附录 C 提交文件格式

预测 CSV 统一以 Person ID 为主键, 字段顺序如下; 类别名称严格使用了赛题英文标签, 概率列按固定类别顺序输出。

字段	类型	说明
Person ID	字符串	样本唯一标识, 与输入数据保持一致
True Label	类别	仅在官方文件要求且提供真值时保留
Predicted Label	类别	任务对应的最终预测标签

模型文件同时保存预处理器、特征顺序、类别映射和随机种子; 推理阶段只允许加载固化对象并生成预测, 不读取测试标签。

附录 D 提交与复现边界

任务一竞赛输出采用 FULL 模型以匹配官方字段条件；论文解释固定采用 NO_TIME_NO_COMPOSITE 口径，两套结果分别回答“可达到的 ACC 上限”和“非定义变量能否泛化”两个问题。

任务三输出标签固定为 Average、Good、Excellent，其中原始 Poor 映射至 Average；四分类分布仅用于数据审计，不参与 ACC3 主结果。

三个任务均在锁定评价后使用全部 10,000 条有标签样本完成最终重训。模型调用严格复用训练阶段的字段清洗、特征构造、编码与类别顺序，不利用测试标签进行任何选择。

附录 E 提交材料结构与命名

平台最终提交三项文件：参赛论文 ADATA2600655.pdf、签字承诺书 ADATA2600655cns.pdf 以及支撑材料 ADATA2600655model.zip。

ADATA2600655model.zip 根目录放置 README_运行说明.pdf 和 DATA2600655 AI 使用说明.pdf。

任务材料按 01_task1、02_task2 和 03_task3 分类整理；每个任务文件夹包含了 code,models,predictions 和对应的 task1_model_report.pdf,task2_model_report.pdf 或 task3_model_report.pdf。

预测 CSV 以 Person ID 为主键，验证结果文件保留 True Label 和 Predicted Label；正式测试输出严格按照平台样例字段生成。

附录 F AI 工具使用声明

本队在完成数据整理、模型训练、公式整理与图表初稿后，使用 ChatGPT 和 Codex 辅助进行文字表述检查、行间距、字体字号及图片排版等工作。

论文中的模型训练、参数选择、指标计算、图表数据与结论均由队员实际运行、核对并最终确认，AI 工具未替代队员进行最终模型评价和结论判定。