

复赛 A 题 · 任务一

睡眠质量评分回归预测

建模思路、验证结果与模型调用说明

队伍编号：DATA2600655

项目	内容
目标变量	Sleep_Quality_Score
数据规模	10,000 条记录、64 列；模型使用 48 个原始输入字段
验证方案	8,000 条开发集五折 OOF；2,000 条固定验证集
最终模型	数值标准化 + 类别独热编码 + Ridge (alpha=1, solver=svd) ; 8,000 条开发记录拟合
开发集 OOF R ²	0.651667
固定验证 R ² / RMSE / MAE	0.634460 / 0.944974 / 0.748283

本报告对应当前模型支撑包中的任务一文件，重点说明特征边界、模型比较、固定验证结果、解释性图件和调用方法。报告所列文件名均与当前压缩包一致。

1 任务目标与数据边界


任务一以 Sleep_Quality_Score 为连续目标，使用人口统计、运动、饮食、生活习惯、生理状态与基础健康指标进行回归预测。Person_ID 仅用于样本对齐，不进入模型。

为避免目标信息直接回流，模型不使用 Sleep_Quality_Score 本身，也不使用 Wake_Up_Time、Sleep_Time、Sleep_Duration_Hours、Number_of_Night_Awakening、Weekend_Sleep_Difference_Hours、Nap_Frequency_Per_Week、Sleep_Disorder_Risk 和 Early_Waker 等直接睡眠变量；同时排除若干综合评分字段。最终模型输入为 48 个原始字段，经预处理后形成 107 维设计矩阵。


特征边界与验证流程

任务一：非睡眠类输入预测睡眠质量；开发集五折选模，锁定验证集一次评价

A 输入契约



B 固定划分与模型评价



说明：预处理仅在相应训练数据上拟合；2,000条锁定验证记录不参与字段选择、模型比较或参数确定。

图1 特征边界与验证流程

1.1 预处理

- 数值字段：训练数据内中位数插补，并使用 StandardScaler 标准化。
- 类别字段：缺失值显式处理，采用 OneHotEncoder；未知类别在推理时忽略。
- 不对目标值进行变换，不删除样本，不在固定验证集上选择参数。


2 候选模型比较与参数选择

模型	五折 R^2 均值	折间标准差	OOF R^2	OOF RMSE	选定
ridge_alpha1	0.651563	0.005342	0.651667	0.939115	是
ridge_001	0.651546	0.005339	0.651650	0.939138	否
hgb_15	0.637616	0.005066	0.637769	0.957666	否
ridge_1000	0.624906	0.007042	0.625029	0.974362	否
rf_128	0.581227	0.006547	0.581426	1.029456	否
extra_128	0.576213	0.009064	0.576431	1.035580	否

在相同 48 个输入字段和相同五折划分上比较 Ridge、HistGradientBoosting、RandomForest 与 ExtraTrees。Ridge $\alpha=1$ 的五折 R^2 均值最高，且与 $\alpha=0.01$ 的差异仅约 1.7×10^{-5} ，因此保留更简洁的 $\alpha=1$ 方案。

开发集五折模型比较

相同48个输入字段、相同五折：Ridge $\alpha=1$ 仍是已考察配置中的最高均值



空心点：各折结果；实心点：五折均值；误差线：折间样本标准差，非置信区间。两种小 α 配置差异不作显著性结论。

图2 开发集五折模型比较


3 固定验证结果

选模完成后，最终任务一 Ridge 流水线使用完整 8,000 条开发记录拟合，并对 2,000 条固定验证记录进行一次独立评价。固定验证集不参与候选模型、字段选择或参数确定。

数据口径	样本数	R^2	RMSE	MAE
开发集 OOF	8,000	0.651667	0.939115	0.752460
固定验证	2,000	0.634460	0.944974	0.748283

预测值与真实评分对照

开发集折外结果与最终内部测试分别展示：使用全部样本，未抽样或裁剪预测



六边形颜色表示样本密度，不改变坐标或预测值。开发集折外n=8,000；锁定测试n=2,000。两个面板坐标范围一致。

图3 开发集与固定验证集真实值—预测值关系

4 误差诊断

固定验证集的 R^2 与开发集 OOF 结果接近，RMSE 与 MAE 也处于相同量级。残差图主要用于检查系统性偏差、异方差与极端误差，不用于再次调整模型。




图4 固定验证集残差与绝对误差诊断


从图中可以看到，残差总体围绕0分布，较大误差主要集中在目标分布两端。该现象说明线性模型能够恢复主要变化趋势，但仍存在个体层面的不可解释波动。

5 特征解释

置换重要性在开发集验证折上计算，用于衡量模型对各输入字段的预测依赖。重要性不表示因果效应，也不能单独作为干预建议。

开发集验证折的特征置换重要性

按原始字段整列置换；48个字段全部计算，本图展示均值最高的12个



每折重复10次，先取折内均值，再汇总5折；误差线为5个折均值的样本标准差，非置信区间。
这是固定模型的预测依赖分析，不是因果贡献；相关特征可能分担重要性。未据此删字段或重新训练。


图 5 开发集置换重要性

重要性结果显示，部分生活方式与生理评分对模型预测贡献较高。由于数据为同批横断面记录，相关变量之间可能存在共同来源或相互关联，因此报告仅解释模型依赖，不作因果推断。

6 数值相关结构

主要数值特征的相关性

开发集n=8,000；按开发集置换重要性选取前10个数值字段，附目标用于描述性对照



睡眠质量评分只用于本图相关性对照，从未作为模型输入。完整34个数值特征与目标的相关矩阵另存CSV。
线性相关不等于因果关系，也不能单凭低相关断言不存在语义泄露；本图不触发任何新特征筛选。

图 6 主要数值字段相关矩阵

相关矩阵用于展示变量间的线性关联结构。岭回归的 L2 正则化可以降低共线方向上的系数波动，但相关关系本身不等于可干预的因果关系。

7 模型调用与文件说明

7.1 运行环境

组件	版本
python	3.12.13
numpy	2.3.5
pandas	2.2.3
scipy	1.17.0
scikit learn	1.8.0
joblib	1.5.3

7.2 预测与复现

安装依赖：python -m pip install -r requirements.txt

预 测 ： python code/predict_task1.py --input data/locked_test_inputs.csv --output my_predictions.csv

复现拟合：python code/train_task1.py --output model_rebuild

7.3 当前包内主要文件

文件	作用
task1_model_report.pdf	本建模报告
model/model.joblib	8,000 条开发记录拟合的最终任务一流水线
model/model_metadata.json	模型参数、训练字段、训练行数与环境记录
model_config.json	输入字段、类别字段及模型参数
code/predict_task1.py	新数据预测入口
code/train_task1.py	按既定方案复现 8,000 条开发集拟合
predictions/validation_predictions.csv	2,000 条固定验证预测
results/model_comparison.csv	候选模型比较结果
results/model_fold_scores.csv	五折逐折指标
figures/	报告与论文图件（6 张 PNG）

模型包用于复现当前结果与生成新数据预测。若赛事另行提供无标签测试集，只需保证输入包含模型所需字段，并使用 predict_task1.py 生成对应预测文件。