

复赛 A 题 · 任务二

工作效率评分回归与驱动因素分析

多重共线性处理、模型验证与解释性分析

队伍编号：DATA2600655

项目	内容
目标变量	Productivity_Score
数据规模	10,000 条记录、64 列
验证方案	8,000 条开发集五折 OOF；2,000 条固定验证集
最终模型	Ridge (alpha=10) 完整预处理流水线
开发集 OOF 调整 R^2	0.615989
固定验证 R^2 / 调整 R^2	0.614099 / 0.594205

本报告对应当前模型支撑包中的任务二文件，同时承担建模说明、运行环境与模型调用说明，给出变量边界、共线性处理、候选模型比较、固定验证结果、驱动因素分析和可复现调用方法。

1 数据理解与预处理

任务二以 Productivity_Score 为连续目标。Person_ID 只用于结果对齐。为减少综合评分回流与同批状态变量造成的循环解释，主模型排除 Health_Score、Fitness_Level、Healthy_Aging_Score、Wellness_Category，以及 Energy_Level_Score、Fatigue_Level_Score、Immune_Health_Score、Mood_Score、Anxiety_Score、Depression_Risk_Score、Focus_Concentration_Score 和 Life_Satisfaction_Score。




图1 Productivity_Score 样本分布

- 数值变量在训练折内中位数插补并标准化。
- 类别变量以显式缺失水平处理后独热编码。
- Wake_Up_Time 与 Sleep_Time 转换为 24 小时周期的正弦/余弦分量。

2 多重共线性审计

变量 A	变量 B	Pearson r
Working_Hours_Per_Day	Sitting_Hours_Per_Day	0.8734
Weight_kg	BMI	0.8434
Exercise_Frequency_Per_Week	Daily_Steps	0.8348
Systolic_BP	Diastolic_BP	0.8320

开发集连续变量中存在多组强相关关系，例如工作时长与久坐时长、体重与 BMI、锻炼频率与日均步数、收缩压与舒张压。任务二不依据单一阈值机械删列，而是通过 Ridge 的 L2 正则化降低共线方向上的系数方差，并使用分组置换重要性解释原始变量的预测依赖。




图 2 连续变量相关结构

3 候选模型比较与选择

模型	OOF R ²	调整 R ²	RMSE	MAE	选定
ElasticNet	0.6211	0.6164	0.7048	0.5612	否
Ridge α=10	0.6207	0.6160	0.7052	0.5616	是
Ridge α=100	0.6205	0.6157	0.7054	0.5619	否
Ridge α=1	0.6205	0.6157	0.7054	0.5617	否
Ridge α=0.1	0.6204	0.6157	0.7055	0.5618	否
HistGradientBoosting	0.6094	0.6046	0.7156	0.5702	否
ExtraTrees	0.5949	0.5899	0.7288	0.5805	否

ElasticNet 的折外调整 R² 略高于 Ridge alpha=10，但差值约 0.00045，低于预设 0.001 容差。考虑到 Ridge 在共线变量下的稳定性与更直接的解释路径，最终采用 Ridge alpha=10。




图 3 候选模型五折 OOF 表现

4 固定验证与误差分析

数据口径	R^2	调整 R^2	RMSE	MAE
开发集 OOF	0.620693	0.615989	0.705211	0.561556
固定验证	0.614099	0.594205	0.718606	0.576399




图 4 固定验证集真实值—预测值

固定验证结果与开发集 OOF 指标接近，说明模型在当前固定划分下具有较好的稳定性。调整 R^2 主口径使用变换后的设计矩阵维数进行惩罚。

5 残差诊断




图 5 固定验证集残差分布与误差结构

残差总体围绕 0 分布。较低与较高生产力评分区域仍存在一定回归向均值现象，因此报告同时保留 MAE 和 RMSE，分别刻画典型误差与较大误差。

6 生产力预测依赖




图 6 生产力模型分组置换重要性

变量	平均重要性
Sleep_Quality_Score	0.2653
Exercise_Frequency_Per_Week	0.2464
Early_Waker	0.2242
Stress_Level	0.1292
Morning_Workout	0.0897

在当前模型中，睡眠质量、每周锻炼频率、Early_Waker、压力水平和晨练是较强的预测依赖。置换重要性用于描述模型依赖，不直接解释为因果效应。

7 精力评分辅助分析




图 7 精力评分辅助模型的生活方式依赖

精力评分辅助模型的开发集 OOF 调整 R^2 为 0.7080。在排除生产力与并发心理状态评分后，锻炼频率、睡眠质量、压力和晨练仍保持较高重要性，说明这些变量在两个相关任务中的排序具有一致性。

8 稳定性与字段口径




图 8 五折性能稳定性




图 9 字段口径消融结果

五折指标波动较小。字段口径消融显示，剔除综合评分与并发状态代理后，预测性能未出现明显下降，同时降低了循环解释和维数惩罚带来的风险。

9 模型调用与文件说明

组件	版本
python	3.13.13
platform	Windows-11-10.0.26200-SP0
numpy	2.3.5
pandas	2.2.3
scipy	1.17.0
scikit learn	1.8.0
matplotlib	3.10.8
joblib	1.5.3

9.1 预测与复现

安装依赖: `python -m pip install -r requirements.txt`

预 测 : `python predict_task2.py --input data/task2_test_input_example.csv --output task2_predictions.csv`

完整复现: `python train_task2.py`

9.2 当前包内主要文件

文件	作用
task2_model_report.pdf	本建模报告
models/task2_final_model.joblib	全量训练的最终推理模型
predict_task2.py	新数据预测入口
train_task2.py	训练、验证、指标和图件复现入口
src/modeling.py	特征工程与回归流水线定义
predictions/validation_predictions.csv	2,000 条固定验证预测
results/run_summary.json	主要指标与模型口径
results/model_comparison.csv	候选模型比较
results/permutation_importance.csv	生产力模型置换重要性
results/energy_driver_importance.csv	精力辅助模型置换重要性
figures/	报告与论文图件 (9 张 PNG)

当前支撑包只保留最终推理模型；固定验证指标由已保存预测文件和结果表复核，不依赖额外的中间模型文件。