

复赛 A 题 · 任务三

综合健康评分回归预测

线性主干、残差集成与泄露控制

队伍编号：DATA2600655

项目	内容
目标变量	Health_Score
数据规模	10,000 条记录、64 列
验证方案	8,000 条开发集五折 OOF；2,000 条固定验证集
最终模型	Ridge 线性主干 + 三路非线性残差加权
开发集 OOF R^2	0.983168
固定验证 R^2 / RMSE / MAE	0.982881 / 1.613125 / 1.286548

本报告对应当前模型支撑包中的任务三文件，同时承担建模说明、运行环境与模型调用说明，重点说明目标泄露控制、特征工程、残差集成、固定验证结果、消融实验和模型调用方法。

1 任务理解与目标泄露控制

任务三预测连续健康综合评分 Health_Score。数据审计发现 Wellness_Category 由 Health_Score 分档形成，属于目标的直接派生标签，因此在训练、验证和推理路径中统一删除。Healthy_Aging_Score 虽与目标高度相关，但并非确定性映射，保留为健康代理指标，并通过消融实验单独评估其影响。




图 1 Health_Score 分布与 Wellness_Category 分档关系

Person_ID 仅用于样本对齐，不进入模型。模型选择与残差权重均在开发集五折 OOF 上完成，固定验证集仅用于最终复核。

2 特征工程与相关结构

- 时间字段转换为 24 小时周期的正弦/余弦分量。
- 数值字段采用训练折内中位数插补、缺失指示与标准化。
- 类别字段采用训练折内插补并独热编码，未知类别在推理时忽略。




图2 目标及主要连续变量相关结构

相关结构显示 Healthy_Aging_Score 与 Health_Score 关联较强，同时心血管风险、BMI、体能、糖尿病风险、睡眠质量和运动相关变量仍提供补充信息。

3 模型结构与候选比较

模型首先使用 Ridge（alpha=0.1）拟合主要线性结构，再分别使用 HistGradientBoosting、ExtraTrees 和 GradientBoosting 学习线性残差。三路残差校正的组合权重由开发集五折 OOF 预测确定。

模型	OOF R ²	RMSE	MAE
OOF 加权残差集成	0.983168	1.588977	1.259917
线性+GBR 残差	0.983062	1.593958	1.264392
线性+HistGB 残差	0.982999	1.596912	1.266977
线性+ExtraTrees 残差	0.982850	1.603919	1.273101
Ridge 线性主干	0.980990	1.688646	1.331884




图 3 候选模型与残差集成性能

加权残差集成在开发集 OOF 上取得最高 $R^2=0.983168$ 。与单一残差模型相比，融合提升有限，但五折结果较稳定。

4 固定验证结果

数据口径	R^2	RMSE	MAE
开发集 OOF	0.983168	1.588977	1.259917
固定验证	0.982881	1.613125	1.286548




图 4 固定验证集真实值—预测值

固定验证 R^2 与开发集 OOF R^2 相差约 0.0003，当前固定划分下没有明显性能落差。

5 残差诊断




图 5 固定验证集残差与误差分布

残差主要集中在 0 附近，目标两端的绝对误差略有上升。报告使用 R^2 、RMSE 和 MAE 共同描述整体拟合与个体误差。

6 特征重要性




图 6 分组置换重要性

Healthy_Aging_Score 是最强的综合代理变量；在其之外，心血管风险、BMI、Fitness_Level、糖尿病风险、睡眠质量和运动相关字段提供稳定的增量贡献。该排序仅描述模型预测依赖。

7 消融与折间稳定性

特征口径	R ²	RMSE	MAE
全部有效特征（剔除直接泄露）	0.982881	1.613125	1.286548
去除 Healthy Aging Score	0.955291	2.606919	2.070348
去除健康衍生评分	0.938333	3.061673	2.420912




图 7 健康代理字段消融结果




图 8 五折 OOF 稳定性

去除 Healthy_Aging_Score 后固定验证 R² 降至 0.955291；进一步去除健康衍生评分后降至 0.938333。五折结果整体波动较小。

8 模型调用与文件说明

组件	版本
python	3.12.13
platform	Linux-6.18.35-x86_64-with-glibc2.39
numpy	2.3.5
pandas	2.2.3
scipy	1.17.0
scikit learn	1.8.0
matplotlib	3.10.8

8.1 预测与复现

安装依赖: `python -m pip install -r requirements.txt`

预 测 : `python predict_task3.py --input data/task3_test_input_example.csv --output task3_predictions.csv`

完整复现: `python train_task3.py`

8.2 当前包内主要文件

文件	作用
task3_model_report.pdf	本建模报告
models/task3_final_model.joblib	全量训练的最终推理模型
predict_task3.py	新数据预测入口
train_task3.py	训练、验证、消融和图件复现入口
src/modeling.py	特征工程与残差集成回归器定义
predictions/validation_predictions.csv	2,000 条固定验证预测
results/run_summary.json	主要指标、环境与残差权重
results/model_comparison.csv	候选模型比较
results/ablation_results.csv	消融实验结果
results/fold_metrics.csv	五折性能
results/permutation_importance.csv	分组置换重要性
figures/	报告与论文图件 (8 张 PNG)

当前残差权重：HistGradientBoosting=0.242201，ExtraTrees=0.372127，GradientBoosting=0.619165。支撑包只保留最终推理模型；固定验证结果由预测文件和结果表复核。